Universidad Distrital Francisco José de Caldas

Proyecto de Inteligencia Computacional II

Análisis y Clasificación de Calcificaciones Mamarias mediante Transfer Learning y Redes Neuronales Convolucionales (ResNet18, ResNet 50 y DenseNet201)

Autores:
Juan Pablo Rojas Ruiz
Kevin Gualteros Jimenez

Bogotá, Colombia
4 de junio de 2026

Índice

1. Introducción y Definición del Problema **5**

2. Marco Teórico y Estado del Arte **5**
2.1. Fundamento Clínico de las Calcificaciones Mamarias 5
2.2. Calcificaciones benignas 5
2.3. Calcificaciones sospechosas o de alto riesgo 6
2.4. Calcificación puntiforme (Punctate) 6
2.5. Importancia de la distribución 6
2.6. Relevancia clínica 6
2.7. Transfer Learning y Arquitectura ResNet18 7
2.8. Transfer Learning y Arquitectura ResNet50 7
2.9. Transfer Learning y Arquitectura DenseNet201 8

3. Modelo de Red Neuronal **8**
3.1. Modelo 8
3.1.1. **1. Enfoque General del Modelo** 9
3.1.2. **2. Transfer Learning con ResNet18** 9

4. Implementación Algorítmica en MATLAB **10**
4.0.1. **1. Integración y Fusión de Datos (Data Engineering)** 11
4.0.2. **2. Extracción y Normalización de Etiquetas** 11
4.0.3. **3. Filtrado Estadístico de Clases** 11
4.0.4. **4. Balanceo de Datos (Undersampling Manual)** 12
4.0.5. **5. Preprocesamiento Avanzado con ROI** 12
4.0.6. **6. Preprocesamiento Masivo y Aceleración** 13
4.0.7. **7. División del Dataset (Train/Validation/Test)** 13
4.0.8. **8. Data Augmentation (Aumento de Datos)** 13
4.0.9. **9. Adaptación de Red Neuronal (Transfer Learning)** 14
4.0.10. **10. Entrenamiento del Modelo** 15
4.0.11. **11. Evaluación del Modelo (Métricas Médicas)** 15
4.0.12. **12. Visualización e Interpretabilidad (Grad-CAM)** 16
4.0.13. **13. Sistema de Prueba Automatizado** 16

5. Tipos de Calcificaciones Mamarias y Diferencias Morfológicas **16**
5.1. Amorphous 17
5.2. Lucent Center 17
5.3. Pleomorphic 17
5.4. Punctate 18
5.5. Round and Regular 18
5.6. Diferencias Generales entre Clases 18
5.7. Importancia en el Modelo de Clasificación 18

6. Análisis de la Distribución de Datos y Balanceo **18**
6.1. Balanceo de Clases . . . 19
6.2. Aumento de Datos (Data Augmentation) . . . 19
6.3. Cantidad Final de Datos para Entrenamiento . . . 20
6.4. Consideración Importante . . . 20

7. Análisis de Resultados – Simulación 1 **20**
7.1. Comportamiento del Entrenamiento . . . 21
7.2. Métricas Promedio del Modelo . . . 22
7.3. Análisis de las Métricas . . . 22
7.4. Interpretación General . . . 22
7.5. Conclusión de la Simulación 1 . . . 22

8. Segunda prueba de entrenamiento de la red neuronal **23**
8.1. Configuración del entrenamiento . . . 23
8.2. Evolución del entrenamiento . . . 23
8.3. Resultados por clase . . . 24
8.4. Métricas globales . . . 25
8.5. Análisis general . . . 25

9. Tercera prueba de entrenamiento de la red neuronal **26**
9.1. Evolución del entrenamiento . . . 26
9.2. Resultados por clase . . . 26
9.3. Métricas globales . . . 26
9.4. Análisis general . . . 27
9.5. Resultados visuales . . . 27

10. Cuarta prueba de entrenamiento de la red neuronal **28**
10.1. Evolución del entrenamiento . . . 28
10.2. Resultados por clase . . . 28
10.3. Métricas globales . . . 28
10.4. Análisis general . . . 29
10.5. Resultados visuales . . . 29

11. Quinta prueba de entrenamiento de la red neuronal **30**
11.1. Evolución del entrenamiento . . . 30
11.2. Resultados por clase . . . 30
11.3. Métricas globales . . . 31
11.4. Resultados visuales . . . 31
11.5. Conclusiones . . . 31

12. Sexta prueba de entrenamiento de la red neuronal **32**
12.1. Resultados del entrenamiento . . . 33
12.2. Resultados por clase . . . 33
12.3. Métricas globales . . . 33
12.4. Resultados visuales . . . 34

13. Análisis comparativo de las seis pruebas **34**
13.1. Comparación de métricas globales . . . 35
13.2. Análisis del comportamiento del modelo . . . 35
13.3. Comportamiento por clases . . . 35
13.4. Conclusiones del análisis comparativo . . . 36

14. Explicabilidad mediante Grad-CAM **36**

15. Comparación entre ResNet18, ResNet50 y DenseNet201 **38**

16. Experimento 1: Fine-Tuning de ResNet50 **39**
16.1. Comportamiento del entrenamiento . . . 39
16.2. Resumen del entrenamiento . . . 40
16.3. Métricas por clase . . . 40
16.4. Métricas globales . . . 40
16.5. Curvas de aprendizaje . . . 40
16.6. Matriz de confusión . . . 41
16.7. Análisis del experimento . . . 41

17. Experimento 2: ResNet50 **42**
17.1. Comportamiento del entrenamiento . . . 42
17.2. Resumen del entrenamiento . . . 42
17.3. Métricas por clase . . . 43
17.4. Métricas globales . . . 43
17.5. Curvas de aprendizaje . . . 43
17.6. Matriz de confusión . . . 44
17.7. Análisis del experimento . . . 44

18. Primera prueba de entrenamiento con DenseNet201 **44**
18.1. Evolución del entrenamiento . . . 45
18.2. Resultados finales del entrenamiento . . . 45
18.3. Métricas globales del modelo . . . 45
18.4. Resultados por clase . . . 46
18.5. Matriz de confusión . . . 46
18.6. Análisis del comportamiento del modelo . . . 46

19. Experimento 2: DenseNet201 **47**
19.1. Comportamiento del entrenamiento . . . 47
19.2. Resumen del entrenamiento . . . 47
19.3. Métricas por clase . . . 47
19.4. Métricas globales . . . 48
19.5. Curvas de aprendizaje . . . 48
19.6. Matriz de confusión . . . 48
19.7. Análisis del experimento . . . 49

20. Comparación de Modelos **49**

21. Análisis de Resultados **50**
21.1. Desempeño de DenseNet201 50
21.2. Desempeño de ResNet50 50
21.3. Análisis de estabilidad 50

22. Análisis por Clase **50**

23. Interfaz Gráfica del Sistema CAD Mamario **50**
23.1. Arquitectura General de la Interfaz 51
23.2. Arquitectura General de la Interfaz 51
23.3. Carga del Modelo y Datos 52
23.4. Generación de Casos Clínicos Aleatorios 53
23.5. Clasificación y Predicción 53
23.6. Interpretabilidad mediante Grad-CAM 53
23.7. Visualización de Probabilidades 53
23.8. Evaluación del Modelo 54
23.9. Historial de Entrenamiento 54
23.10Conclusión de la Interfaz 54

24. Conclusiones **54**

1. Introducción y Definición del Problema

El cáncer de mama es una de las principales causas de mortalidad femenina a nivel global. Su detección temprana depende en gran medida del análisis de mamografías, siendo las calcificaciones uno de los biomarcadores radiológicos más críticos.

El presente proyecto aborda la clasificación automatizada de cinco tipos morfológicos de calcificaciones mamarias (*Amorphous*, *Lucent Center*, *Pleomorphic*, *Punctate* y *Round/Regular*) utilizando la base de datos pública CBIS-DDSM (Curated Breast Imaging Subset of DDSM).

Dada la altísima similitud visual entre estas anomalías, la variabilidad del tejido mamario y el ruido inherente a los equipos de rayos X, este problema representa un desafío clásico y complejo de visión por computadora.

El objetivo principal de este proyecto es desarrollar un modelo basado en Redes Neuronales Convolucionales (CNN) capaz de extraer características discriminativas de alto nivel, evaluando su rendimiento mediante métricas clínicas rigurosas y validando su interpretabilidad a través de mapas de activación visual (Grad-CAM).

2. Marco Teórico y Estado del Arte

2.1. Fundamento Clínico de las Calcificaciones Mamarias

Las calcificaciones mamarias son depósitos de sales de calcio dentro del tejido mamario que se observan como estructuras hiperdensas en las mamografías. Representan uno de los hallazgos más importantes en el diagnóstico temprano del cáncer de mama, ya que ciertos patrones morfológicos están altamente asociados con malignidad, especialmente con el carcinoma ductal in situ (CDIS).

Según la literatura radiológica, la evaluación de las calcificaciones se basa principalmente en dos criterios fundamentales: **morfología** y **distribución**. Estos descriptores permiten clasificar las lesiones según su probabilidad de malignidad dentro del sistema BI-RADS.

2.2. Calcificaciones benignas

Las calcificaciones benignas suelen presentar bordes definidos, formas regulares y mayor tamaño. Generalmente no requieren intervención inmediata. Entre ellas se destacan:

- **Calcificaciones vasculares:** lineales paralelas asociadas a arterias mamarias.
- **Calcificaciones cutáneas:** de localización superficial con centro radiolúcido.
- **Calcificaciones en pop corn:** asociadas a fibroadenomas en involución.
- **Calcificaciones distróficas:** relacionadas con necrosis grasa postquirúrgica o traumática.
- **Calcificaciones en anillo:** típicas de quistes con contenido graso.
- **Calcificaciones redondas o puntiformes:** depósitos de oxalato de calcio, usualmente benignos si son difusos.

2.3. Calcificaciones sospechosas o de alto riesgo

Estas presentan mayor relevancia clínica debido a su asociación con lesiones premalignas o malignas:

- **Calcificaciones amorfas:** extremadamente pequeñas ($< 0{,}1$ mm), sin forma definida, con riesgo moderado de malignidad.
- **Calcificaciones pleomórficas:** heterogéneas en forma y tamaño, altamente sospechosas de carcinoma ductal in situ.
- **Calcificaciones lineales finas o ramificadas:** representan moldes de conductos afectados por necrosis tumoral, con el mayor valor predictivo positivo de malignidad (hasta 70 %).
- **Calcificaciones groseras heterogéneas:** pueden estar asociadas a lesiones benignas o malignas dependiendo de su patrón de distribución.

2.4. Calcificación puntiforme (Punctate)

Dentro de las microcalcificaciones redondas, las calcificaciones puntiformes se caracterizan por su tamaño menor a 0.5 mm y su forma redondeada uniforme. Generalmente se consideran benignas cuando aparecen de forma aislada o difusa. Sin embargo, cuando se presentan agrupadas pueden requerir seguimiento, ya que pueden corresponder a lesiones de bajo grado o cambios fibroquísticos iniciales.

2.5. Importancia de la distribución

La distribución de las calcificaciones es tan importante como su morfología. Los patrones más relevantes son:

- **Difusa:** generalmente benigna.
- **Agrupada:** requiere evaluación adicional.
- **Segmentaria o lineal:** altamente sugestiva de malignidad.

2.6. Relevancia clínica

Un aspecto clave es que más del 50 % de los cánceres mamarios no palpables pueden manifestarse únicamente como microcalcificaciones en mamografía. Por esta razón, la correcta clasificación morfológica y estadificación BI-RADS es esencial para el diagnóstico temprano.

En la práctica clínica, la coexistencia de múltiples descriptores en una misma lesión determina la categoría final, seleccionando siempre la de mayor sospecha.

2.7. Transfer Learning y Arquitectura ResNet18

Entrenar una CNN desde cero para aplicaciones médicas es inviable debido a la escasez de datos etiquetados. Por ello, se utiliza el *Transfer Learning* (Aprendizaje Transferido), técnica que toma una red previamente entrenada con millones de imágenes genéricas y aprovecha sus filtros convolucionales base.

Se seleccionó la arquitectura **ResNet18** (Residual Network). Su innovación matemática radica en las conexiones residuales (*skip connections*), las cuales permiten sortear el problema del desvanecimiento del gradiente.

En lugar de forzar a las capas a aprender el mapeo completo $H(x)$, ResNet optimiza una función residual $F(x) = H(x) - x$, permitiendo un flujo directo de información a través de la red.

2.8. Transfer Learning y Arquitectura ResNet50

Con el objetivo de incrementar la capacidad de representación del modelo y capturar patrones morfológicos más complejos en las calcificaciones mamarias, se evaluó adicionalmente la arquitectura **ResNet50**.

ResNet50 pertenece a la familia de Redes Residuales (Residual Networks) propuesta por He et al. y constituye una extensión más profunda de ResNet18. Mientras ResNet18 posee aproximadamente 18 capas entrenables y cerca de 11 millones de parámetros, ResNet50 incrementa significativamente su profundidad hasta 50 capas convolucionales y más de 25 millones de parámetros.

La principal característica de ResNet50 sigue siendo el uso de conexiones residuales (*skip connections*), las cuales permiten que la información y los gradientes fluyan directamente entre capas no consecutivas. Esto evita el problema del desvanecimiento del gradiente (*Vanishing Gradient*) y facilita el entrenamiento de redes mucho más profundas.

A diferencia de ResNet18, ResNet50 emplea bloques residuales del tipo *Bottleneck*, compuestos por tres convoluciones sucesivas:

- Convolución 1×1 para reducción dimensional.
- Convolución 3×3 para extracción de características.
- Convolución 1×1 para expansión dimensional.

Esta estrategia permite aumentar considerablemente la profundidad de la red sin incrementar excesivamente el costo computacional.

Desde una perspectiva clínica, una mayor profundidad permite detectar patrones radiológicos más sutiles, especialmente en clases complejas como *Amorphous*, *Pleomorphic* y *Punctate*, cuyas diferencias morfológicas son difíciles de capturar mediante arquitecturas menos profundas.

Sin embargo, el incremento en la cantidad de parámetros también aumenta el riesgo de sobreajuste cuando se dispone de conjuntos de datos reducidos, como ocurre frecuentemente en aplicaciones médicas.

2.9. Transfer Learning y Arquitectura DenseNet201

Además de las arquitecturas residuales, se evaluó la red **DenseNet201** (Densely Connected Convolutional Network), una de las arquitecturas más avanzadas utilizadas en clasificación de imágenes médicas.

DenseNet201 fue propuesta por Huang et al. con el objetivo de maximizar la reutilización de características aprendidas durante el entrenamiento. Su principal innovación consiste en conectar cada capa con todas las capas anteriores dentro de un mismo bloque denso.

Matemáticamente, la salida de una capa no depende únicamente de la capa inmediatamente anterior, sino de la concatenación de todas las salidas previas:

$$x_l = H_l([x_0, x_1, x_2, \ldots, x_{l-1}])$$

donde:

- x_l representa la salida de la capa actual.
- H_l representa la transformación aprendida.
- $[\cdot]$ denota la operación de concatenación.

Esta estrategia presenta varias ventajas importantes:

- Mejora el flujo del gradiente durante el entrenamiento.
- Reduce el problema del desvanecimiento del gradiente.
- Favorece la reutilización de características.
- Disminuye la redundancia en el aprendizaje.

DenseNet201 posee aproximadamente 20 millones de parámetros distribuidos en 201 capas profundas, permitiendo aprender representaciones altamente discriminativas incluso cuando las diferencias visuales entre clases son extremadamente sutiles.

En aplicaciones de análisis mamográfico, esta capacidad resulta especialmente valiosa debido a que muchas microcalcificaciones presentan variaciones mínimas de forma, textura y distribución espacial.

Por esta razón, DenseNet201 ha sido ampliamente utilizada en problemas de diagnóstico asistido por computador (CAD) y clasificación de imágenes médicas de alta complejidad.

3. Modelo de Red Neuronal

3.1. Modelo

El modelo propuesto sigue un flujo estructurado que integra procesamiento de datos médicos, técnicas de aprendizaje profundo y evaluación clínica. A continuación, se presenta el diagrama de bloques del sistema completo.

El modelo desarrollado se basa en una arquitectura de **Deep Learning con Transfer Learning**, utilizando la red preentrenada ResNet18 como núcleo principal para la clasificación de calcificaciones mamarias.

3.1.1. 1. Enfoque General del Modelo

El sistema sigue un flujo estructurado donde las imágenes médicas son transformadas progresivamente hasta convertirse en una predicción clínica:

- Entrada: mamografía + máscara ROI
- Preprocesamiento especializado
- Extracción de características profundas (CNN)
- Clasificación multiclase

Este enfoque permite aprovechar tanto la información radiológica como el poder de representación de redes convolucionales profundas.

3.1.2. 2. Transfer Learning con ResNet18

En lugar de entrenar una red desde cero, se emplea **Transfer Learning**, reutilizando los pesos aprendidos por ResNet18 en millones de imágenes (ImageNet).

La ventaja clave es que:

- Las primeras capas ya detectan patrones básicos (bordes, texturas)
- Las capas profundas se adaptan al problema médico específico

Además, se modifica la arquitectura original:

- Se eliminan las capas finales de clasificación (1000 clases)
- Se reemplazan por una capa totalmente conectada adaptada a **5 clases clínicas**

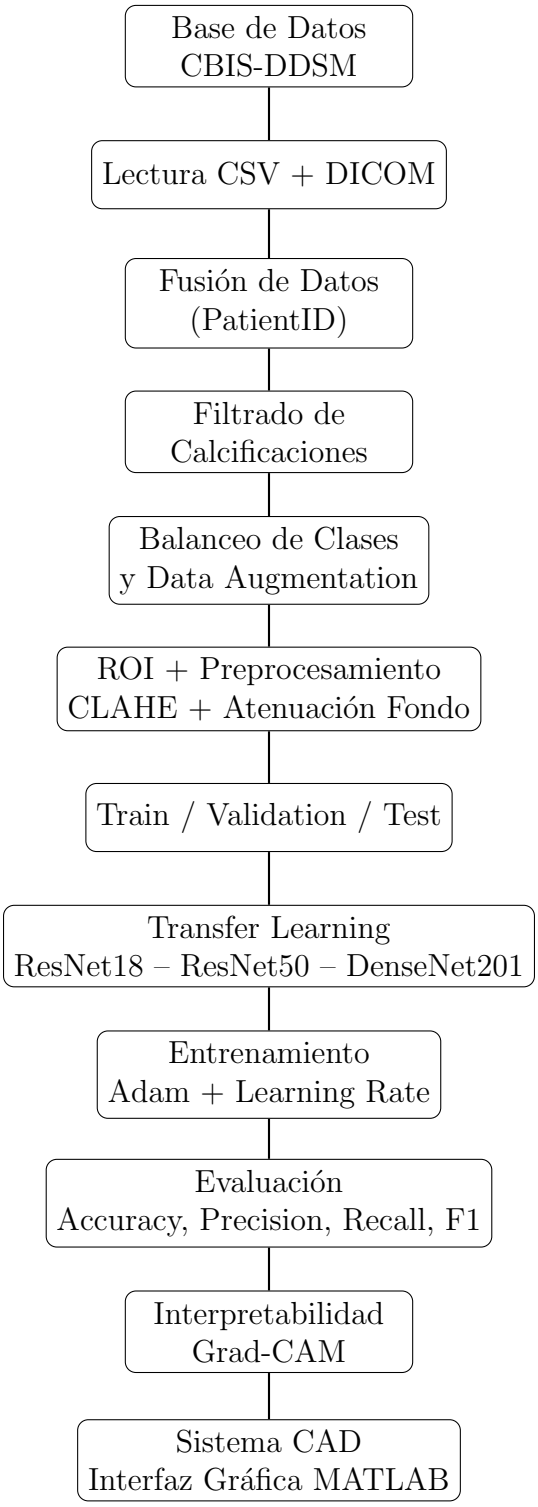


Figura 1: Pipeline completo del modelo de clasificación de calcificaciones mamarias.

4. Implementación Algorítmica en MATLAB

El desarrollo del proyecto se llevó a cabo en el entorno de MATLAB, estructurando un pipeline de procesamiento robusto que aborda desde la extracción de datos en formato

JPEG hasta la evaluación de métricas de desempeño. A continuación, se desglosan los módulos principales del código implementado.

4.0.1. 1. Integración y Fusión de Datos (Data Engineering)

La base de datos CBIS-DDSM distribuye la información en archivos CSV para la descripción clínica y las rutas de los archivos de imagen. El primer paso algorítmico consistió en leer ambas tablas y unificarlas (operación de *inner join*) utilizando el identificador único del paciente (`PatientID`).

```
% Lectura de CSV + DICOM Info
calc_info  = readtable(fullfile(basePath,"csv","
    calc_case_description_train_set.csv"));
dicom_info = readtable(fullfile(basePath,"csv","dicom_info.csv"));

% Extraccion de PatientID para cruce
calc_info.PatientID = extractBefore(calc_info.imageFilePath, "/");
dicom_info.image_path = erase(dicom_info.image_path,"CBIS-DDSM/jpeg/");

% JOIN relacional (Solo imagenes de calcificaciones)
joined = innerjoin(dicom_info, calc_info, "Keys","PatientID");
joined = joined(string(joined.abnormalityType) == "calcification", :);
```

Listing 1: Lectura y unificación de datos CSV e imágenes

Esta metodología garantiza que ninguna imagen quede huérfana de su etiqueta clínica correspondiente, preservando la integridad del dataset de entrenamiento.

Objetivo algorítmico: Garantizar consistencia entre imagen, ROI y etiqueta clínica.

Resultado: Dataset limpio, estructurado y listo para procesamiento supervisado.

4.0.2. 2. Extracción y Normalización de Etiquetas

Se diseñó un algoritmo para:

- Procesar el campo `calcType`
- Separar subcategorías usando delimitadores (`-`)
- Convertir etiquetas a formato categórico (`categorical`)

Ventaja: Estandariza las clases y elimina ruido semántico en los labels.

4.0.3. 3. Filtrado Estadístico de Clases

Una exploración inicial de los datos reveló un desbalance severo (la clase *Pleomorphic* superaba ampliamente a las demas clases . Entrenar una red neuronal bajo estas condiciones induce un sesgo inaceptable hacia la clase mayoritaria.

Para solucionar esto, primero se filtraron las clases con menos de 100 muestras. Luego, se aplicó un algoritmo de *Undersampling* manual, forzando a que todas las clases seleccionadas aportaran exactamente la misma cantidad de imágenes (`minCount` = 101).

```
% Identificar el conteo de la clase minoritaria
minCount = min(counts);
idxBalanced = [];

for i = 1:numel(cats)
    idxClass = find(labels == cats{i});

    % Seleccion aleatoria (randperm) sin reemplazo
    idxClass = idxClass(randperm(numel(idxClass), minCount));
    idxBalanced = [idxBalanced; idxClass];
end

% Re-asignacion balanceada
imagePaths = imagePaths(idxBalanced);
labels     = labels(idxBalanced);
```

Listing 2: Algoritmo de balanceo estricto de clases

La función `randperm` asegura que en cada ejecución las imágenes se seleccionen de forma pseudo-aleatoria, lo que dota al proceso de mayor robustez estadística al no escoger siempre los primeros registros.

Objetivo: Reducir ruido estadístico y evitar clases poco representativas.

4.0.4. 4. Balanceo de Datos (Undersampling Manual)

Se desarrolló un algoritmo propio de balanceo:

- Identificación de la clase minoritaria
- Selección aleatoria uniforme (`randperm`)
- Igualación del número de muestras por clase

Resultado: Dataset completamente balanceado → evita sesgo del modelo.

4.0.5. 5. Preprocesamiento Avanzado con ROI

El núcleo del procesamiento se implementa en una función personalizada:

Etapas clave:

- Conversión a escala de grises
- Redimensionamiento (224×224)
- Aplicación de máscara ROI
- Atenuación del fondo (30 %)
- Conversión a 3 canales

Importancia:
Este bloque es crítico, ya que:

- Reduce ruido del tejido sano
- Destaca la región patológica
- Mejora la calidad de entrada a la CNN

4.0.6. 6. Preprocesamiento Masivo y Aceleración

Se implementó un enfoque eficiente:

- Preprocesamiento offline de todas las imágenes
- Almacenamiento en archivo `.mat`

Ventaja:

- Reduce tiempo de entrenamiento
- Evita recomputación innecesaria
- Permite uso eficiente de GPU

4.0.7. 7. División del Dataset (Train/Validation/Test)

Se utilizó:
`cvpartition`con 70/20/10 **Objetivo:**

- Separar datos de entrenamiento, validacion y prueba
- Garantizar evaluación imparcial del modelo

4.0.8. 8. Data Augmentation (Aumento de Datos)

Dado el elevado peso computacional de las imágenes médicas, se implementó el uso de `arrayDatastore` combinado con la función `transform`.

Esto permite que las imágenes se carguen y procesen en memoria RAM únicamente en el momento exacto en que la red las solicita.

El núcleo del procesamiento reside en la función `preprocessMammoROI`, la cual extrae la máscara (*Region of Interest*) y atenúa el ruido del tejido sano al 30 %, multiplicando los píxeles fuera de la máscara por un factor de 0,3. Posteriormente, se clona la matriz a 3 canales usando `repmat` para cumplir con la topología de entrada de la arquitectura ResNet18 ($224 \times 224 \times 3$).

Adicionalmente, se integró aumento de datos (*Data Augmentation*) exclusivamente al conjunto de entrenamiento mediante espejado dinámico:

```
function dataOut = readAndAugmentData(data, globalClasses)
    % Carga base
    dataOut_temp = readData(data, globalClasses);
    I = dataOut_temp{1}; label = dataOut_temp{2};

    % Transformaciones Estocasticas (50% de probabilidad)
    if rand() > 0.5
```

```
        I = fliplr(I); % Espejado horizontal
    end
    if rand() > 0.5
        I = flipud(I); % Espejado vertical
    end

    dataOut = {I, label};
end
```

Listing 3: Funcion de aumento de datos integrado

Implementado con `imageDataAugmenter`:

- Reflexión horizontal y vertical
- Rotación ($\pm 10°$)
- Traslaciones

Aplicación: Solo en entrenamiento → evita fuga de información en test.

4.0.9. 9. Adaptación de Red Neuronal (Transfer Learning)

Se utilizó la red preentrenada ResNet18 con modificaciones:

- Eliminación de capas finales
- Inserción de:
  - Dropout
  - Fully Connected
  - Softmax

Para emplear Transfer Learning con ResNet18, se procedió a retirar la capa `fc1000` (diseñada originalmente para 1000 clases de ImageNet) y se sustituyó por una arquitectura terminal adaptada a nuestras 5 categorías médicas.

Crucialmente, se inyectó una capa de **Dropout (30 %)** (`dropoutLayer(0.3)`). Esta técnica probabilística desactiva el 30 % de los nodos de forma aleatoria durante cada iteración, previniendo la coadaptación de neuronas y obligando a la red a no depender de patrones aislados para su predicción, lo cual es fundamental para mitigar el *overfitting*.

```
net = resnet18;
lgraph = layerGraph(net);
numClasses = numel(categories(trainLbl));

% Nueva topologia final
newLayers = [
    dropoutLayer(0.2, 'Name', 'new_dropout')
    fullyConnectedLayer(numClasses, 'Name', 'new_fc', '
    WeightLearnRateFactor', 10)
    softmaxLayer('Name', 'new_prob')
    classificationLayer('Name', 'new_classoutput')
];
```

```
12
13 % Extraccion y sustitucion
14 lgraph = removeLayers(lgraph, {'fc1000', 'prob', '
       ClassificationLayer_predictions'});
15 lgraph = addLayers(lgraph, newLayers);
16 lgraph = connectLayers(lgraph, 'pool5', 'new_dropout');
```

Listing 4: Modificacion topologica del Layer Graph

Objetivo: Adaptar el modelo a clasificación médica multiclase.

4.0.10. 10. Entrenamiento del Modelo

Configuración mediante `trainingOptions`:

- Optimizador: Adam
- Learning rate adaptativo (schedule)
- Mini-batch: 32
- Uso de GPU
- Validación periódica

Estrategias clave:

- Reducción progresiva del learning rate
- Control del sobreajuste
- Monitoreo continuo del desempeño

4.0.11. 11. Evaluación del Modelo (Métricas Médicas)

Se implementó un cálculo manual de métricas:
A partir de la matriz de confusión:

- Precisión
- Sensibilidad (Recall)
- Especificidad
- F1-Score

Ventaja: Permite análisis clínico detallado por clase.

4.0.12. 12. Visualización e Interpretabilidad (Grad-CAM)

Se implementó:

- Generación de mapas de activación
- Superposición sobre imagen original

Objetivo:

- Validar que la red aprende regiones relevantes
- Aumentar confianza en el modelo

4.0.13. 13. Sistema de Prueba Automatizado

Se desarrolló un algoritmo robusto para test:

- Selección aleatoria de imágenes
- Validación automática de rutas
- Manejo de errores con reintentos

Resultado: Sistema estable para pruebas en datos reales.

5. Tipos de Calcificaciones Mamarias y Diferencias Morfológicas

Las calcificaciones mamarias son depósitos de calcio que aparecen como pequeñas regiones hiperdensas en las mamografías. Su análisis morfológico es fundamental en la detección temprana del cáncer de mama, ya que su forma, tamaño y distribución están altamente correlacionados con la probabilidad de malignidad.

En este proyecto se trabajan cinco tipos principales de calcificaciones provenientes de la base de datos CBIS-DDSM, las cuales se describen a continuación:

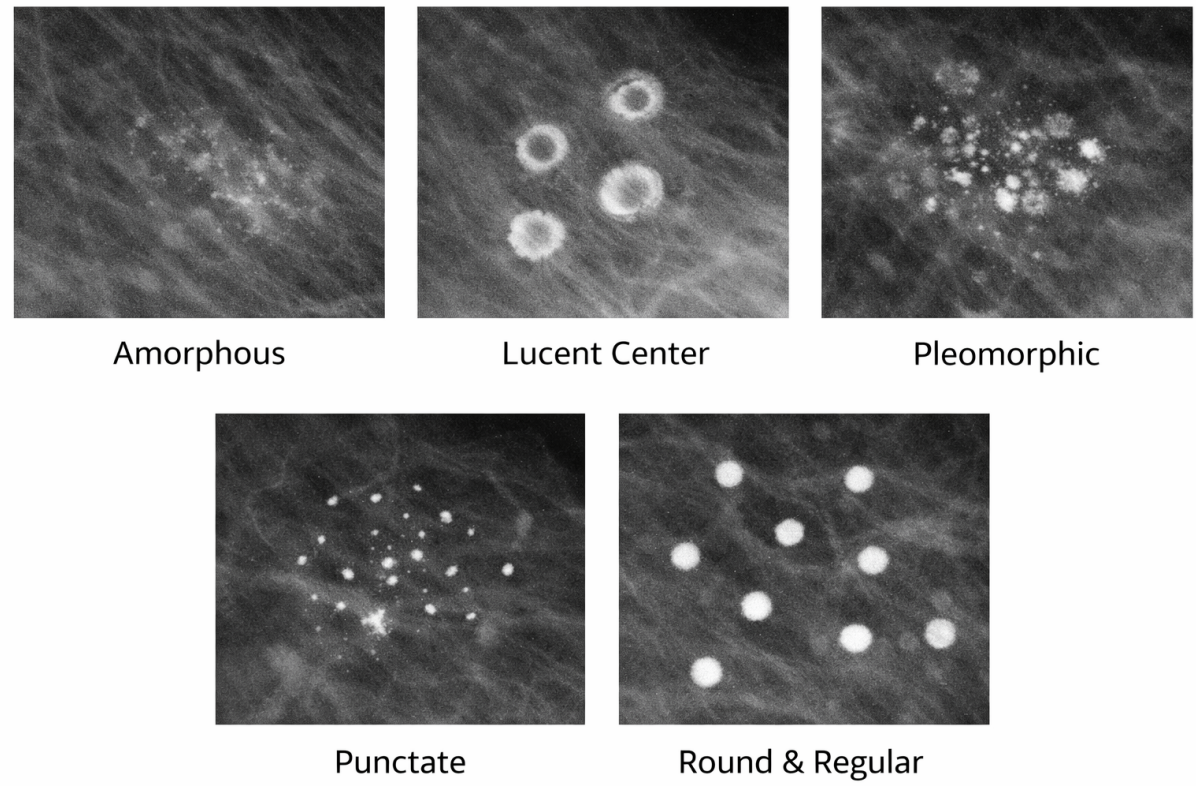


Figura 2: Tipos de calcificaciones

5.1. Amorphous

Las calcificaciones *Amorphous* son microcalcificaciones extremadamente pequeñas y mal definidas, con bordes difusos que dificultan su visualización. No presentan una forma geométrica clara y suelen agruparse en regiones pequeñas.

Desde el punto de vista clínico, son consideradas de **baja a moderada sospecha**, aunque su naturaleza indefinida puede requerir análisis adicional.

5.2. Lucent Center

Las calcificaciones *Lucent Center* presentan una estructura bien definida con un centro radiolúcido (más oscuro) rodeado por un borde calcificado. Su forma suele ser redondeada u ovalada.

Estas calcificaciones están generalmente asociadas a procesos **benignos**, como secreciones en conductos o cambios degenerativos del tejido mamario.

5.3. Pleomorphic

Las calcificaciones *Pleomorphic* son altamente irregulares tanto en forma como en tamaño. Pueden presentarse como agrupaciones heterogéneas con variaciones significativas entre partículas individuales.

Este tipo es considerado de **alta sospecha de malignidad**, ya que frecuentemente se asocia a carcinoma ductal in situ (DCIS).

5.4. Punctate

Las calcificaciones *Punctate* son pequeñas, puntiformes y relativamente uniformes. Pueden aparecer dispersas o en pequeños grupos.

Aunque en algunos casos pueden ser benignas, su presencia en agrupaciones densas puede indicar un **riesgo intermedio**, lo que las convierte en una de las clases más difíciles de clasificar automáticamente debido a su similitud con otras microcalcificaciones.

5.5. Round and Regular

Las calcificaciones *Round and Regular* presentan formas circulares u ovaladas bien definidas, con bordes suaves y homogéneos. Su morfología es consistente y simétrica.

Este tipo está fuertemente asociado a condiciones **benignas**, siendo uno de los patrones más fácilmente identificables tanto por radiólogos como por modelos de aprendizaje automático.

5.6. Diferencias Generales entre Clases

Las principales diferencias entre los tipos de calcificaciones radican en tres factores morfológicos clave:

- **Forma:** Desde estructuras regulares (Round and Regular) hasta altamente irregulares (Pleomorphic).
- **Tamaño:** Desde microcalcificaciones puntiformes (Punctate) hasta estructuras más visibles y definidas (Lucent Center).
- **Bordes:** Claros y definidos en casos benignos, difusos o irregulares en casos sospechosos.

5.7. Importancia en el Modelo de Clasificación

Estas diferencias morfológicas representan el principal desafío del modelo de clasificación, ya que algunas clases como *Amorphous*, *Punctate* y *Pleomorphic* presentan una alta similitud visual, lo que incrementa la dificultad de separación para redes neuronales convolucionales.

Por el contrario, clases como *Lucent Center* y *Round and Regular* presentan patrones más definidos, lo que facilita su correcta identificación por parte del modelo.

6. Análisis de la Distribución de Datos y Balanceo

El conjunto de datos inicial utilizado para el entrenamiento está compuesto por un total de **1546 imágenes** correspondientes a cinco clases de calcificaciones mamarias. La distribución original presenta un desbalance significativo entre clases, como se muestra a continuación:

Cuadro 1: Distribución original de clases

Clase	**Cantidad de Imágenes**
Amorphous	153
Lucent Center	101
Pleomorphic	693
Punctate	150
Round and Regular	126

Se observa que la clase *Pleomorphic* domina ampliamente el conjunto de datos, representando cerca del 45 % del total, mientras que otras clases presentan una cantidad considerablemente menor de muestras. Este desbalance introduce un sesgo en el entrenamiento, ya que el modelo tendería a favorecer la clase mayoritaria.

6.1. Balanceo de Clases

Para mitigar este problema, se aplicó una estrategia de *undersampling*, igualando todas las clases al tamaño de la clase minoritaria significativa (101 imágenes). El resultado es el siguiente:

Cuadro 2: Distribución de clases después del balanceo

Clase	**Cantidad de Imágenes**
Amorphous	101
Lucent Center	101
Pleomorphic	101
Punctate	101
Round and Regular	101

Como resultado del balanceo, el conjunto de entrenamiento queda conformado por un total de:

505 imágenes balanceadas

Este procedimiento garantiza que todas las clases tengan la misma representación, eliminando el sesgo hacia clases dominantes y permitiendo un aprendizaje más equitativo.

6.2. Aumento de Datos (Data Augmentation)

Con el fin de mejorar la capacidad de generalización del modelo y compensar la reducción de datos producto del undersampling, se implementaron técnicas de *Data Augmentation* aplicadas exclusivamente al conjunto de entrenamiento.

Las transformaciones utilizadas incluyen:

- Reflexión horizontal y vertical

- Rotaciones aleatorias en el rango de $\pm 10°$
- Traslaciones en los ejes X e Y

Estas transformaciones generan variaciones sintéticas de las imágenes originales en cada iteración de entrenamiento, sin aumentar físicamente el tamaño del dataset en memoria.

6.3. Cantidad Final de Datos para Entrenamiento

Aunque el dataset balanceado contiene **505 imágenes únicas**, el uso de *Data Augmentation* implica que el modelo es expuesto a múltiples variaciones de cada imagen durante el entrenamiento.

Por lo tanto:

- Datos reales: 505 imágenes
- Datos efectivos durante entrenamiento: significativamente mayores (virtualmente aumentados)

Esto permite mejorar la robustez del modelo sin necesidad de adquirir nuevas imágenes médicas.

6.4. Consideración Importante

Es importante destacar que todos los datos descritos corresponden exclusivamente al conjunto de **entrenamiento**. El conjunto de prueba se mantiene sin alteraciones ni aumento de datos, con el objetivo de garantizar una evaluación objetiva del desempeño del modelo.

7. Análisis de Resultados – Simulación 1

El modelo fue entrenado durante 35 épocas utilizando la arquitectura basada en Transfer Learning con ResNet18. Durante el proceso de entrenamiento se observó una mejora progresiva en la precisión del conjunto de entrenamiento, alcanzando un valor final de 74.19 %, mientras que la precisión en validación se estabilizó alrededor del 50.50 %. Esta diferencia evidencia un comportamiento de sobreajuste (overfitting), donde el modelo aprende correctamente los patrones del conjunto de entrenamiento pero presenta dificultades para generalizar a datos no vistos.

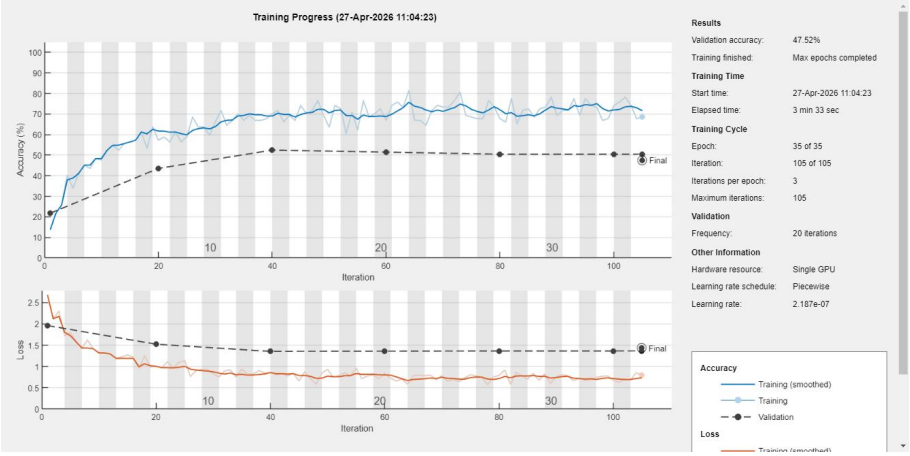


Figura 3: Prueba1

7.1. Comportamiento del Entrenamiento

Durante las primeras épocas, el modelo presenta un aprendizaje rápido, aumentando significativamente la precisión desde valores cercanos al azar hasta más del 60 % en entrenamiento. Sin embargo, a partir de la mitad del proceso, la mejora en validación se detiene, indicando que el modelo deja de generalizar y comienza a especializarse en patrones del conjunto de entrenamiento.

La diferencia entre la precisión de entrenamiento (74.19 %) y validación (50.50 %) confirma un nivel moderado–alto de sobreajuste.

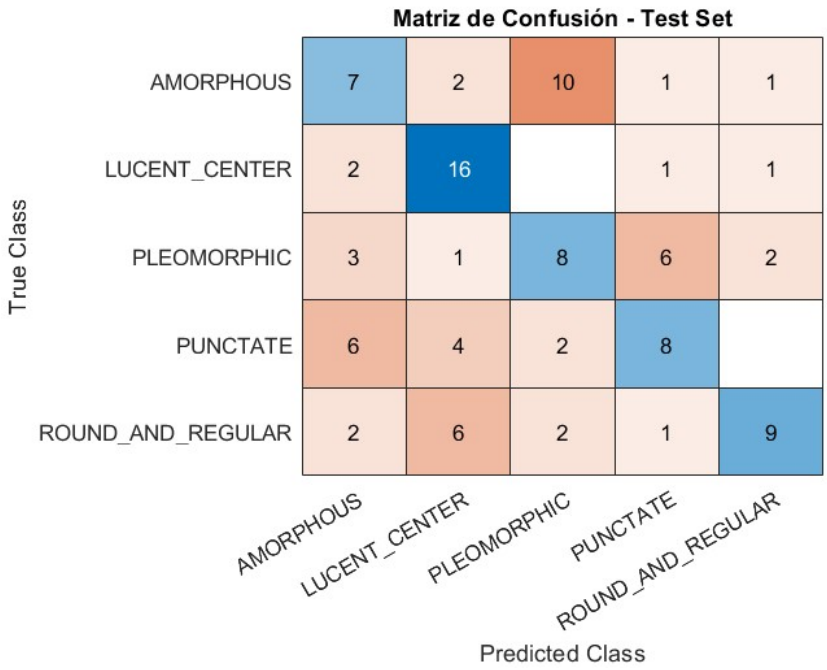


Figura 4: Matriz de confusion

7.2. Métricas Promedio del Modelo

Cuadro 3: Métricas promedio del modelo (Simulación 1)

Métrica	**Valor (%)**
Precisión (Macro)	48.56
Sensibilidad (Macro)	47.67
Especificidad (Macro)	86.87
F1-Score (Macro)	47.07

7.3. Análisis de las Métricas

Las métricas obtenidas permiten caracterizar el comportamiento del modelo desde una perspectiva clínica:

- **Especificidad (86.87 %):** El modelo presenta una alta capacidad para identificar correctamente los casos negativos, lo que indica una baja tasa de falsos positivos. Este comportamiento refleja un modelo conservador en sus predicciones.
- **Sensibilidad (47.67 %):** La capacidad del modelo para detectar correctamente los casos positivos es baja, lo que implica una alta tasa de falsos negativos. En un contexto médico, este comportamiento es crítico, ya que podría implicar la no detección de calcificaciones relevantes.
- **Precisión (48.56 %):** Indica que aproximadamente la mitad de las predicciones positivas son correctas, evidenciando dificultad en la separación entre clases con alta similitud morfológica.
- **F1-Score (47.07 %):** Refleja un rendimiento global limitado, producto del desequilibrio entre precisión y sensibilidad.

7.4. Interpretación General

El modelo muestra un comportamiento sesgado hacia la reducción de falsos positivos, priorizando la especificidad sobre la sensibilidad. Aunque esto puede parecer favorable en ciertos contextos, en aplicaciones médicas puede resultar problemático, ya que incrementa la probabilidad de no detectar lesiones relevantes.

Adicionalmente, la brecha entre el rendimiento en entrenamiento y validación confirma la presencia de sobreajuste, probablemente influenciado por el tamaño del mini-batch y la baja variabilidad efectiva del conjunto de datos.

7.5. Conclusión de la Simulación 1

En esta primera simulación, el modelo demuestra capacidad de aprendizaje, pero limitada capacidad de generalización. El comportamiento observado sugiere la necesidad de ajustar hiperparámetros como el tamaño del mini-batch y reforzar técnicas de regularización o aumento de datos para mejorar la robustez del modelo en escenarios no vistos.

8. Segunda prueba de entrenamiento de la red neuronal

En esta segunda fase experimental se ajustaron los hiperparámetros del proceso de entrenamiento con el objetivo de mejorar la capacidad de generalización del modelo y estabilizar la convergencia. Se utilizó el optimizador **Adam** con una tasa de aprendizaje inicial de 3×10^{-4}, incorporando un esquema de reducción escalonada (*piecewise*) para disminuir progresivamente la tasa de aprendizaje durante el entrenamiento.

8.1. Configuración del entrenamiento

La configuración empleada fue la siguiente:

- Número máximo de épocas: 35
- Tamaño del mini-batch: 64
- Estrategia de mezcla de datos: shuffle en cada época
- Datos de validación: `augimdsTest`
- Frecuencia de validación: cada 20 iteraciones
- Paciencia de validación: 20 iteraciones
- Factor de reducción de la tasa de aprendizaje: 0.3
- Período de reducción: cada 5 épocas
- Entorno de ejecución: GPU

8.2. Evolución del entrenamiento

Durante el proceso de entrenamiento se observó una mejora progresiva en la precisión del conjunto de entrenamiento, alcanzando valores cercanos al 82.81 % en las mejores iteraciones. Sin embargo, la precisión de validación se mantuvo significativamente más baja, fluctuando aproximadamente entre 41 % y 48 %, lo que indica una capacidad limitada de generalización del modelo hacia datos no vistos.

La pérdida de entrenamiento disminuyó desde valores iniciales cercanos a 2.70 hasta aproximadamente 0.52, mientras que la pérdida de validación se mantuvo relativamente estable alrededor de 1.45 a 1.51, lo cual refuerza la presencia de una brecha entre el aprendizaje del conjunto de entrenamiento y validación.

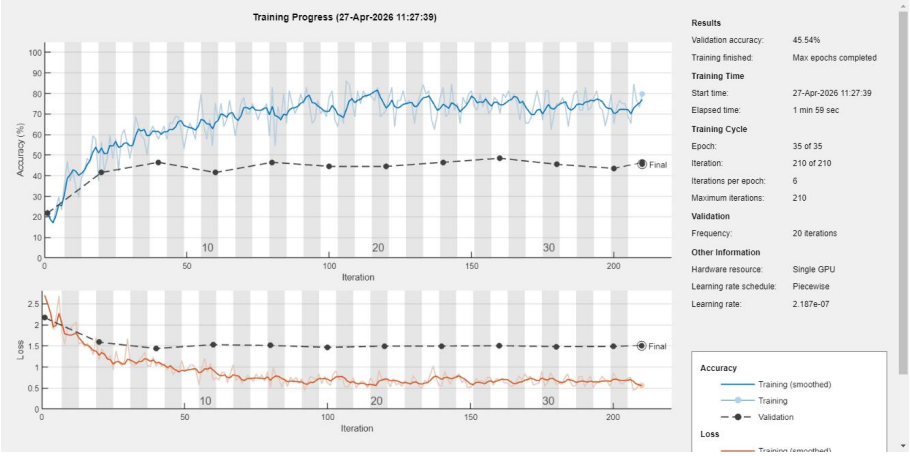


Figura 5: prueba 2

8.3. Resultados por clase

El desempeño del modelo varió considerablemente entre las distintas clases analizadas:

- La clase **"LUCENT_CENTER"** obtuvo el mejor desempeño global, con una sensibilidad del 80 % y un F1-score de 68.09 %.
- Las clases **"PLEOMORPHIC"** y **"PUNCTATE"** presentaron resultados intermedios, con F1-scores de 31.11 % y 40 %, respectivamente.
- La clase **.ªMORPHOUS"** mostró el rendimiento más bajo, con una sensibilidad de 19.05 %, evidenciando dificultades significativas en su detección.
- La clase **ROUND_AND_REGULAR"** alcanzó un desempeño moderado con un F1-score de 55.56 %.

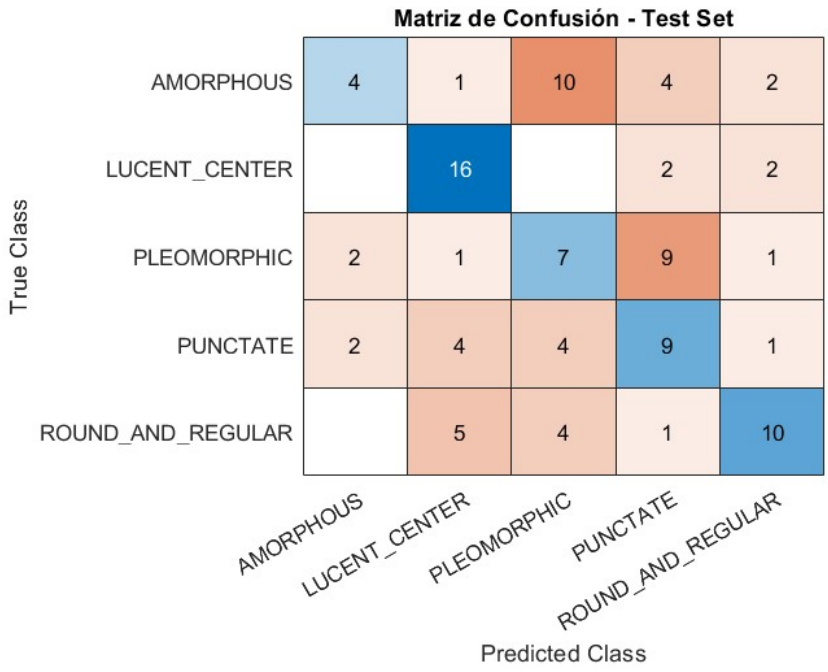


Figura 6: Matriz de confusion

8.4. Métricas globales

El rendimiento promedio del modelo en las cinco clases fue el siguiente:

- Precisión macro promedio: 47.15 %
- Sensibilidad macro promedio: 45.81 %
- Especificidad macro promedio: 86.41 %
- F1-score macro promedio: 44.47 %

8.5. Análisis general

Aunque el modelo logra aprender patrones relevantes en el conjunto de entrenamiento, la diferencia entre el desempeño de entrenamiento y validación sugiere un comportamiento de **sobreajuste leve a moderado**. Esto se evidencia en la caída de la precisión de validación y la estabilidad relativa de la pérdida de validación.

En general, esta configuración mejora la estabilidad del entrenamiento respecto a pruebas previas, pero aún no es suficiente para lograr una generalización óptima en todas las clases, especialmente en aquellas con menor representación o mayor variabilidad intraclase.

9. Tercera prueba de entrenamiento de la red neuronal

En esta tercera fase experimental se mantuvieron los mismos hiperparámetros generales del modelo utilizado en la prueba anterior, con el objetivo de evaluar la influencia de una modificación específica en el tamaño del *mini-batch*. En particular, el único cambio realizado en la configuración fue la reducción del tamaño del *mini-batch* de 64 a 32, buscando incrementar la frecuencia de actualización de los pesos y mejorar la capacidad de ajuste del modelo durante el entrenamiento.

9.1. Evolución del entrenamiento

Durante el proceso de entrenamiento se observó una mejora progresiva en la precisión del modelo, alcanzando valores cercanos al 84.38 % en el conjunto de entrenamiento. La precisión de validación mostró un comportamiento más estable en comparación con pruebas anteriores, oscilando aproximadamente entre 46 % y 53 %.

La función de pérdida en el conjunto de entrenamiento disminuyó hasta valores cercanos a 0.44–0.52 en sus mejores iteraciones, mientras que la pérdida de validación se mantuvo relativamente estable alrededor de 1.27 a 1.43. Esto indica una ligera mejora en la capacidad de generalización del modelo respecto a configuraciones previas.

9.2. Resultados por clase

El desempeño del modelo varió entre las distintas clases evaluadas:

- La clase **"LUCENT_CENTER"** obtuvo el mejor rendimiento, con una sensibilidad del 85 % y un F1-score de 73.91 %, consolidándose como la clase más fácil de identificar.
- La clase **ROUND_AND_REGULAR"** alcanzó un desempeño moderado con un F1-score de 54.55 %.
- La clase **.ᴬMORPHOUS"** mostró una mejora respecto a pruebas anteriores, con un F1-score de 45 %.
- Las clases **"PLEOMORPHIC"** y **"PUNCTATE"** presentaron un desempeño más limitado, con F1-scores de 35 % y 32.56 %, respectivamente.

9.3. Métricas globales

El rendimiento promedio del modelo en esta configuración fue el siguiente:

- Precisión macro promedio: 49.48 %
- Sensibilidad macro promedio: 48.57 %
- Especificidad macro promedio: 87.13 %
- F1-score macro promedio: 48.20 %

9.4. Análisis general

La reducción del tamaño del *mini-batch* a 32 permitió una actualización más frecuente de los gradientes, lo cual contribuyó a una ligera mejora en la estabilidad del entrenamiento y en las métricas globales del modelo. Aunque la ganancia no es drástica, se observa una mejora consistente en la precisión promedio y en el F1-score macro respecto a la prueba anterior.

Sin embargo, aún persiste una brecha entre el desempeño en entrenamiento y validación, lo que sugiere que el modelo sigue presentando un grado moderado de sobreajuste.

9.5. Resultados visuales

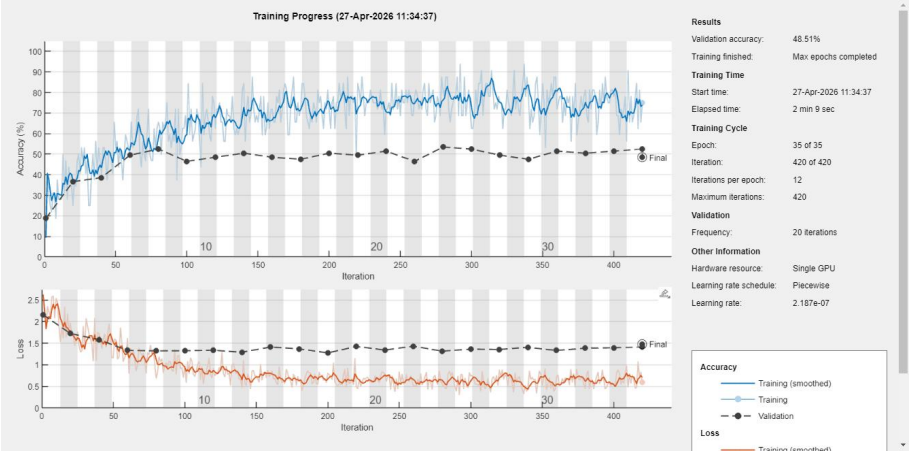


Figura 7: Prueba3

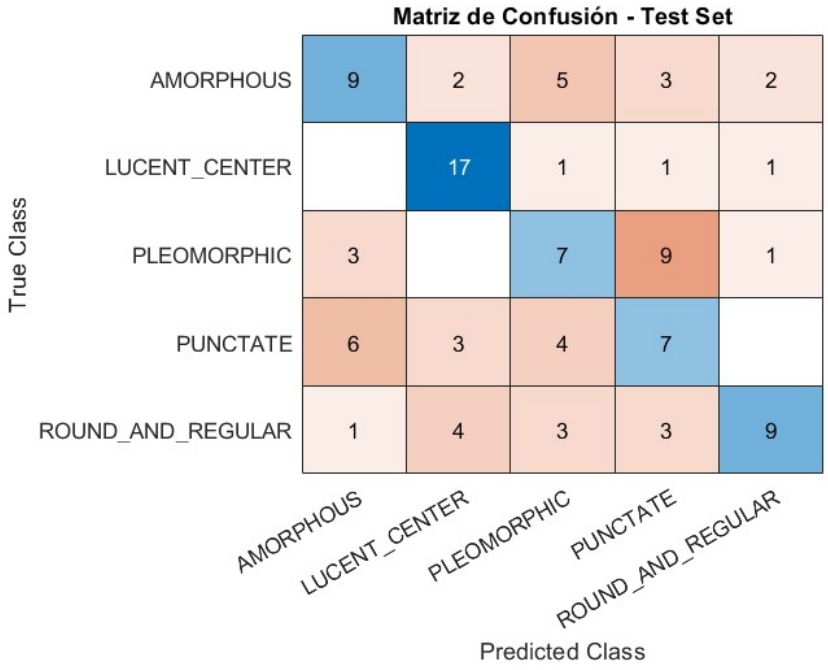


Figura 8: Confusion

10. Cuarta prueba de entrenamiento de la red neuronal

En esta cuarta fase experimental se mantuvieron los hiperparámetros generales de la configuración anterior, realizando una modificación específica en el tamaño del *mini-batch*, el cual se redujo de 32 a 16. Adicionalmente, se ajustó la frecuencia de validación, reduciéndola de 20 a 10 iteraciones, con el objetivo de monitorear de manera más frecuente el comportamiento del modelo durante el entrenamiento.

10.1. Evolución del entrenamiento

Durante el proceso de entrenamiento se observó un comportamiento más inestable en comparación con las pruebas anteriores, con variaciones significativas en la precisión del conjunto de entrenamiento, alcanzando valores máximos cercanos al 87.50 %. La precisión de validación se mantuvo en un rango aproximado entre 41 % y 52 %, sin mostrar una mejora sostenida a lo largo de las épocas.

La función de pérdida en el conjunto de entrenamiento presentó fluctuaciones importantes, mientras que la pérdida de validación se mantuvo relativamente estable alrededor de 1.25 a 1.48. El entrenamiento finalizó al cumplirse el criterio de validación establecido.

10.2. Resultados por clase

El desempeño del modelo por clase fue el siguiente:

- La clase **"LUCENT_CENTER"** obtuvo el mejor rendimiento, con una sensibilidad del 80 % y un F1-score de 71.11 %.
- La clase **ROUND_AND_REGULAR"** alcanzó un desempeño equilibrado con un F1-score de 55 %.
- La clase **"PUNCTATE"** presentó un rendimiento moderado con un F1-score de 37.84 %.
- La clase **.ªMORPHOUS"** mostró un bajo desempeño con un F1-score de 33.33 %.
- La clase **"PLEOMORPHIC"** obtuvo el rendimiento más bajo con un F1-score de 26.32 %.

10.3. Métricas globales

El rendimiento promedio del modelo en esta configuración fue:

- Precisión macro promedio: 44.26 %
- Sensibilidad macro promedio: 45.67 %
- Especificidad macro promedio: 86.38 %
- F1-score macro promedio: 44.72 %

10.4. Análisis general

La reducción del tamaño del *mini-batch* a 16 no generó una mejora significativa en el desempeño del modelo. Aunque se incrementa la frecuencia de actualización de los gradientes, esto también introduce mayor variabilidad en el entrenamiento, lo cual se refleja en la inestabilidad de la precisión.

Adicionalmente, la reducción de la frecuencia de validación permitió un monitoreo más detallado del comportamiento del modelo, pero no se evidenció una mejora clara en la capacidad de generalización. En general, esta configuración no supera el desempeño de las pruebas anteriores.

10.5. Resultados visuales

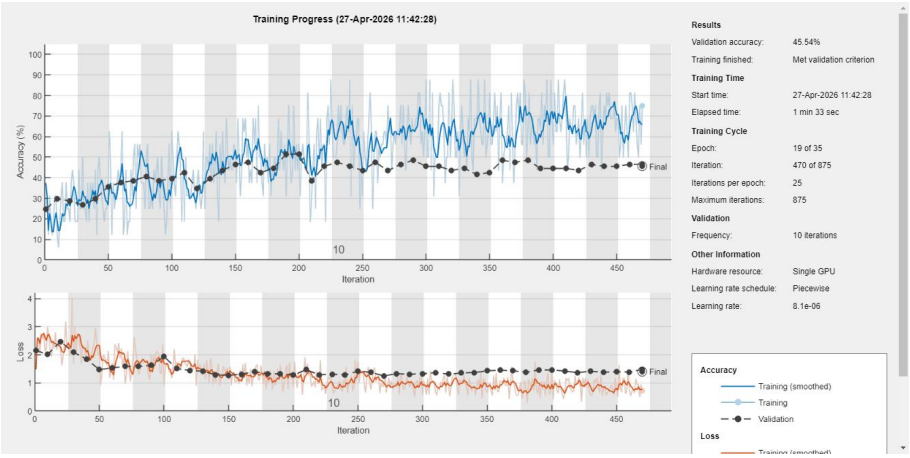


Figura 9: Prueba 4

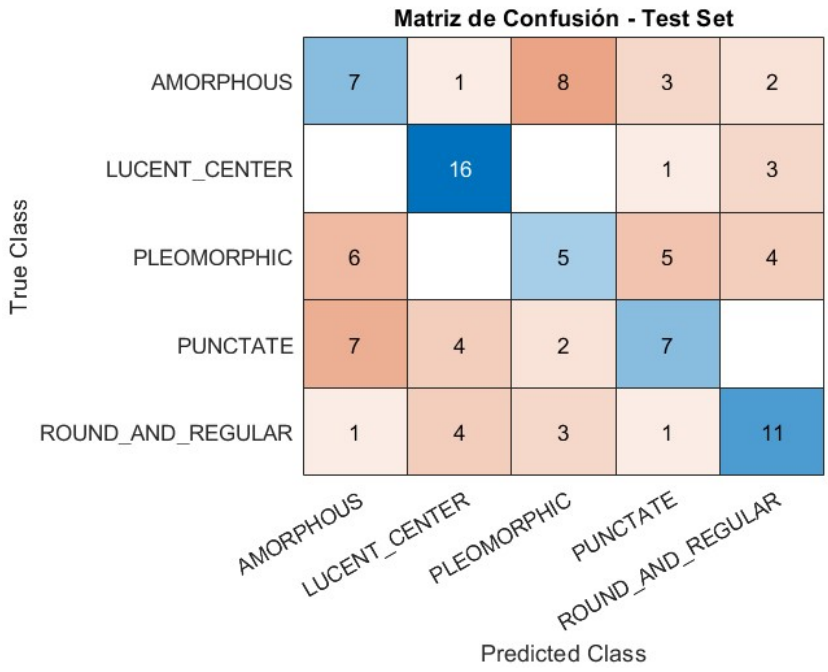


Figura 10: Matriz de confusion

11. Quinta prueba de entrenamiento de la red neuronal

En esta quinta fase experimental se realizaron ajustes en los hiperparámetros del modelo con el objetivo de mejorar la capacidad de generalización. En particular, se redujo la tasa de aprendizaje inicial a 1×10^{-4}, manteniendo el tamaño del *mini-batch* en 32. Esta modificación buscó estabilizar el proceso de optimización y permitir un aprendizaje más fino de los pesos de la red.

11.1. Evolución del entrenamiento

Durante el entrenamiento se observó una mejora significativa en la precisión del conjunto de entrenamiento, alcanzando valores cercanos al 93.75 %. La precisión de validación mostró un comportamiento más estable en comparación con pruebas anteriores, llegando hasta un valor máximo de 56.44 %, lo que representa el mejor desempeño de validación obtenido hasta el momento.

La función de pérdida en el conjunto de entrenamiento disminuyó de forma consistente hasta valores cercanos a 0.17, mientras que la pérdida de validación se mantuvo alrededor de 1.50 a 1.95, con algunas fluctuaciones. Esto indica una mejora en la capacidad de ajuste del modelo, aunque aún persiste una diferencia entre el desempeño en entrenamiento y validación.

11.2. Resultados por clase

El desempeño del modelo por clase fue el siguiente:

- La clase **"LUCENT_CENTER"** obtuvo el mejor rendimiento, con una sensibilidad del 80 % y un F1-score de 76.19 %, consolidándose como la clase más fácilmente identificable.
- La clase **ROUND_AND_REGULAR"** presentó un buen desempeño con un F1-score de 64.71 %.
- La clase **.^MORPHOUS"** mostró una mejora significativa respecto a pruebas anteriores, alcanzando un F1-score de 60 %.
- Las clases **"PLEOMORPHIC"** y **"PUNCTATE"** continuaron siendo las más difíciles de clasificar, con F1-scores de 39.02 % y 35.56 %, respectivamente.

11.3. Métricas globales

El rendimiento promedio del modelo en esta configuración fue el siguiente:

- Precisión macro promedio: 56.91 %
- Sensibilidad macro promedio: 54.43 %
- Especificidad macro promedio: 88.62 %
- F1-score macro promedio: 55.10 %

11.4. Resultados visuales

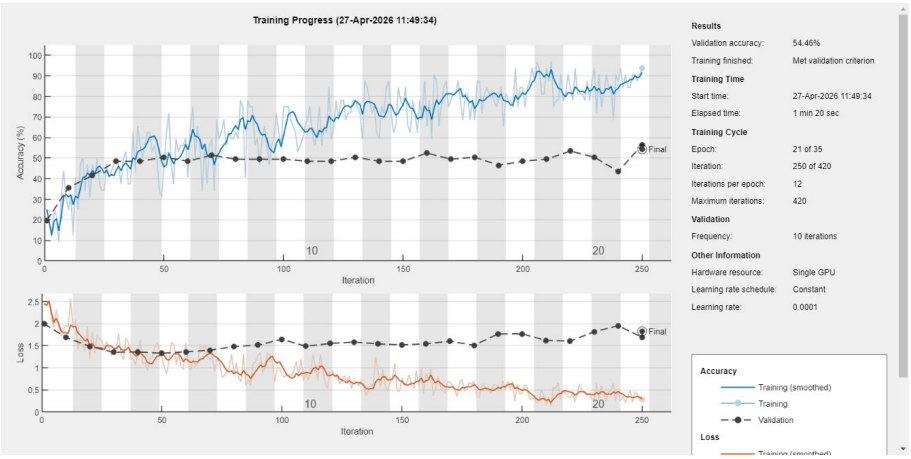


Figura 11: Prueba 5

11.5. Conclusiones

A partir de las cinco pruebas realizadas, se observa una evolución progresiva en el desempeño del modelo al ajustar los hiperparámetros de entrenamiento. En particular, la reducción de la tasa de aprendizaje a 1×10^{-4} en la quinta prueba permitió obtener los mejores resultados globales, alcanzando una precisión macro promedio de 56.91 % y un F1-score de 55.10 %, superando las configuraciones anteriores.

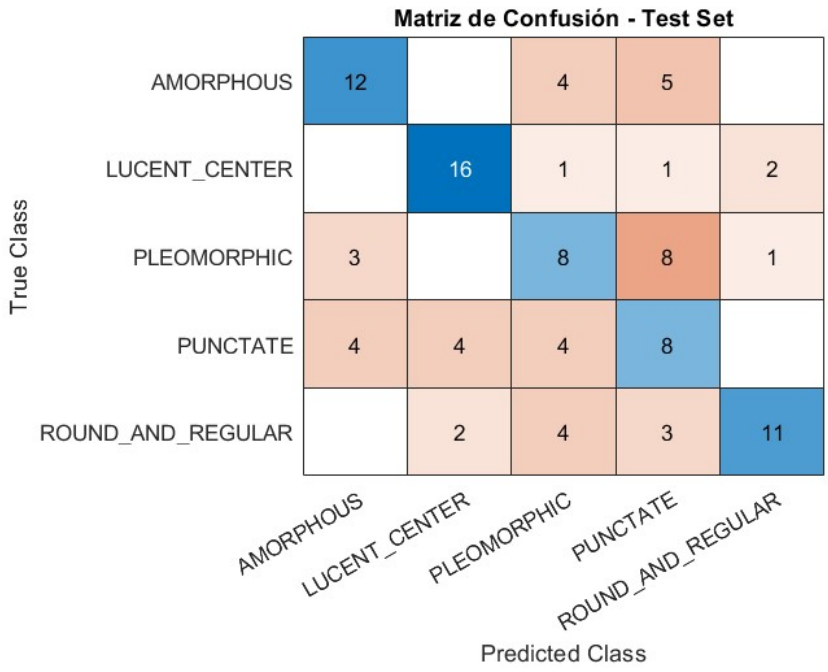


Figura 12: Matriz de confusion

Este comportamiento indica que un aprendizaje más lento y controlado favorece la generalización del modelo, reduciendo la inestabilidad observada en configuraciones previas. Adicionalmente, se evidencia una mejora consistente en varias clases, especialmente en *AMORPHOUS* y *ROUND_AND_REGULAR*, lo que sugiere una mejor capacidad de discriminación del modelo.

Sin embargo, a pesar de las mejoras obtenidas, persiste una brecha entre el rendimiento en entrenamiento y validación, lo que indica que el modelo aún presenta cierto grado de sobreajuste. Las clases *PLEOMORPHIC* y *PUNCTATE* continúan siendo las más difíciles de clasificar, posiblemente debido a su alta variabilidad y similitud con otras clases.

En conclusión, la quinta configuración representa el mejor equilibrio general entre estabilidad y desempeño, aunque aún existen oportunidades de mejora mediante técnicas como regularización adicional, aumento de datos más robusto o el uso de arquitecturas preentrenadas.

12. Sexta prueba de entrenamiento de la red neuronal

En esta sexta fase experimental se mantuvieron los hiperparámetros generales de la configuración 3, menos la configuracion del uso del metodo de PIECEWISE para una tasa variable de aprendizaje con el objetivo de evaluar la estabilidad del modelo bajo condiciones similares de entrenamiento y validar la consistencia de los resultados obtenidos en la quinta prueba.

12.1. Resultados del entrenamiento

S se observó una mejora significativa en el desempeño global. El modelo alcanzó una precisión macro promedio de 62.01 % y un F1-score macro promedio de 59.54 %, representando los mejores resultados obtenidos hasta el momento.

El comportamiento por clase mostró una mejor capacidad de generalización, especialmente en las clases con mayor dificultad en pruebas anteriores.

12.2. Resultados por clase

El desempeño del modelo por clase fue el siguiente:

- La clase **ROUND_AND_REGULAR"** obtuvo el mejor rendimiento, con un F1-score de 75.68 % y una sensibilidad del 70 %, mostrando una alta capacidad de identificación.
- La clase **"PUNCTATE"** presentó un buen desempeño con un F1-score de 62.22 %, evidenciando una mejora significativa respecto a pruebas anteriores.
- La clase **"LUCENT_CENTER"** mantuvo un rendimiento sólido con un F1-score de 68.42 % y una precisión del 76.47 %.
- La clase **"PLEOMORPHIC"** mostró una mejora importante en sensibilidad (60 %), alcanzando un F1-score de 48.98 %.
- La clase **.ªMORPHOUS"** continuó siendo la más desafiante, con un F1-score de 42.42 %, aunque con una mejora en precisión respecto a pruebas anteriores.

12.3. Métricas globales

El rendimiento promedio del modelo en esta configuración fue el siguiente:

- Precisión macro promedio: 62.01 %
- Sensibilidad macro promedio: 59.38 %
- Especificidad macro promedio: 89.86 %
- F1-score macro promedio: 59.54 %

12.4. Resultados visuales

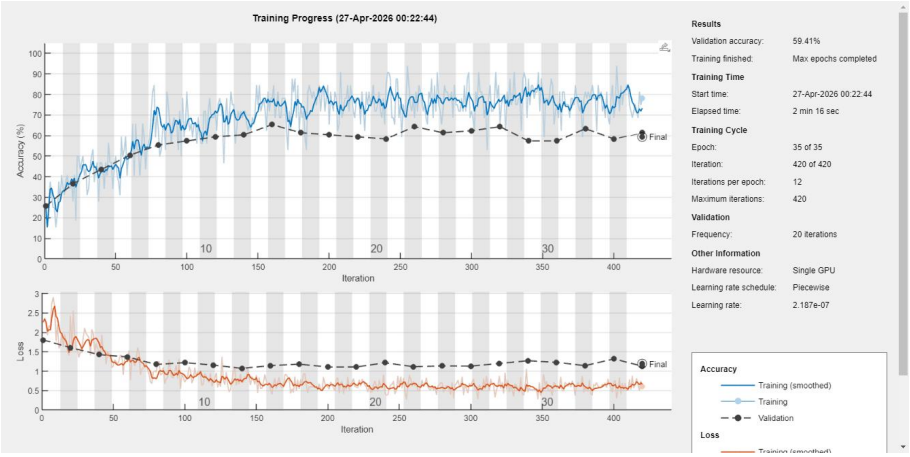


Figura 13: Mejor prueba

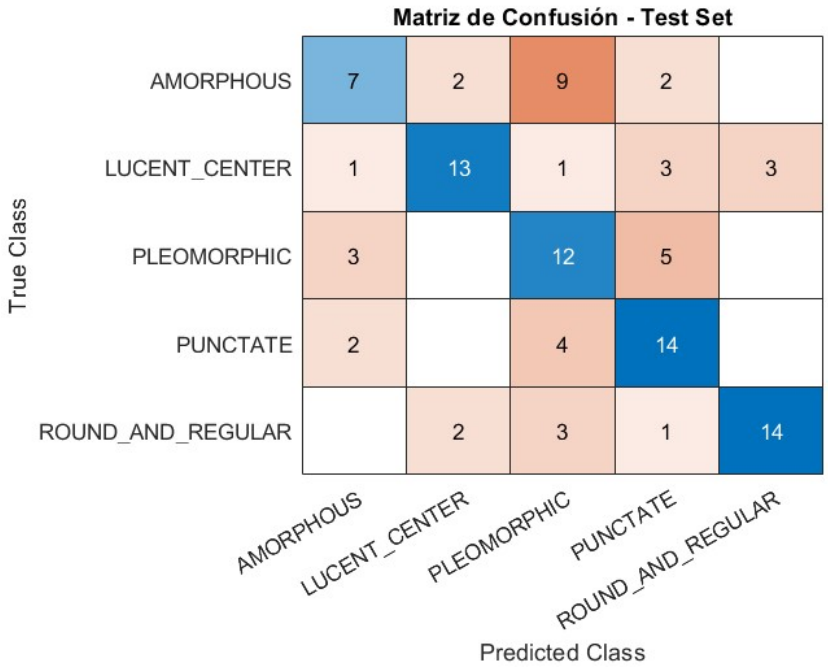


Figura 14: Matriz de confusion

13. Análisis comparativo de las seis pruebas

En esta sección se realiza un análisis comparativo de las seis configuraciones evaluadas durante el entrenamiento de la red neuronal convolucional, con el objetivo de identificar el impacto de los cambios en los hiperparámetros sobre el desempeño global del modelo.

13.1. Comparación de métricas globales

A continuación, se resumen las métricas macro promedio obtenidas en cada una de las pruebas:

- **Prueba 1:** Precisión 47.15 %, Sensibilidad 45.81 %, F1-score 44.47 %
- **Prueba 2:** Precisión 49.48 %, Sensibilidad 48.57 %, F1-score 48.20 %
- **Prueba 3:** Precisión 49.48 %, Sensibilidad 48.57 %, F1-score 48.20 %
- **Prueba 4:** Precisión 44.26 %, Sensibilidad 45.67 %, F1-score 44.72 %
- **Prueba 5:** Precisión 56.91 %, Sensibilidad 54.43 %, F1-score 55.10 %
- **Prueba 6:** Precisión 62.01 %, Sensibilidad 59.38 %, F1-score 59.54 %

Se observa una tendencia general de mejora progresiva a partir de la quinta prueba, alcanzando los mejores resultados en la sexta configuración.

13.2. Análisis del comportamiento del modelo

El análisis comparativo permite identificar los siguientes comportamientos clave:

- Las primeras pruebas (1 a 4) muestran un desempeño bajo y altamente inestable, con F1-scores inferiores al 50 %, lo que indica una capacidad de generalización limitada y sensibilidad alta a los cambios de hiperparámetros.
- La tercera prueba presentó un mejor equilibrio relativo dentro del grupo inicial, sugiriendo que un *mini-batch* intermedio (32) favorece la estabilidad del aprendizaje.
- La cuarta prueba evidenció que una reducción excesiva del *mini-batch* (16) no mejora el rendimiento, e incluso puede introducir mayor variabilidad en el proceso de entrenamiento.
- A partir de la quinta prueba, se observa una mejora significativa en todas las métricas, especialmente al reducir la tasa de aprendizaje a 1×10^{-4}, lo cual permitió un aprendizaje más estable y progresivo.
- La sexta prueba representa el mejor desempeño global del modelo, alcanzando los valores más altos en precisión, sensibilidad y F1-score macro, lo que indica una mejor capacidad de generalización.

13.3. Comportamiento por clases

De forma consistente en todas las pruebas, se identifican patrones claros entre las clases:

- **LUCENT_CENTER** es la clase con mejor desempeño general, manteniéndose estable en todas las configuraciones.

- **ROUND_AND_REGULAR** presenta también un rendimiento alto en las últimas pruebas.
- **PLEOMORPHIC** y **PUNCTATE** son las clases más difíciles de clasificar, con variabilidad significativa en sus métricas.
- **AMORPHOUS** mejora progresivamente, pero sigue siendo una clase desafiante en términos de sensibilidad.

13.4. Conclusiones del análisis comparativo

El análisis global de las seis pruebas permite concluir que el desempeño del modelo está fuertemente influenciado por la tasa de aprendizaje y el tamaño del *mini-batch*. En particular, configuraciones con tasas de aprendizaje más bajas (1×10^{-4}) y *mini-batch* intermedio (32) o moderado muestran mejores resultados en términos de generalización.

La mejor configuración global corresponde a la sexta prueba, con un F1-score macro de 59.54 % y una precisión macro de 62.01 %, lo que representa una mejora significativa respecto a las primeras pruebas.

Sin embargo, a pesar de las mejoras obtenidas, persiste una brecha entre el desempeño en entrenamiento y validación, lo que indica la presencia de sobreajuste residual. Esto sugiere que, aunque el modelo ha mejorado su capacidad de aprendizaje, aún existen oportunidades de optimización mediante técnicas como regularización, aumento de datos o uso de arquitecturas preentrenadas.

En conclusión, el proceso experimental demuestra que la correcta selección de hiperparámetros es fundamental para mejorar el desempeño de redes neuronales convolucionales, siendo la sexta configuración la más robusta y estable dentro del conjunto evaluado.

14. Explicabilidad mediante Grad-CAM

Para asegurar que la red neuronal basara sus decisiones matemáticas en el tejido mamario anómalo y no en el fondo atenuado de la imagen, se generaron mapas de calor de activación (Grad-CAM).

- **Caso 1 - Pleomorphic:** La red logró una predicción exitosa con una altísima confianza del **83.65 %**. El mapa de calor (Figura 15) demuestra que los filtros convolucionales se activaron exactamente en las regiones de mayor densidad y agrupamiento del tejido.

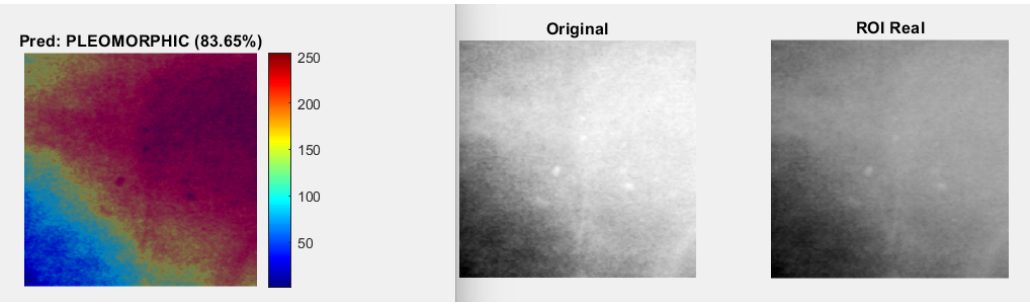


Figura 15: Análisis Grad-CAM para caso Pleomorphic. Predicción correcta con 83.65 % de confianza.

- **Caso 2 - Punctate:** A pesar de ser la clase más compleja para el modelo a nivel global, en este caso específico la red logró una clasificación correcta con una confianza del **63.16 %** (Figura 16), validando que la etapa de preprocesamiento (atenuación del fondo al 30 %) fue efectiva para destacar microcalcificaciones.

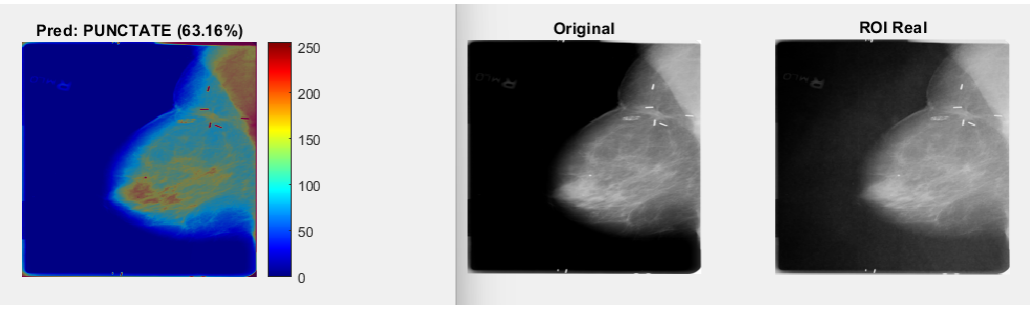


Figura 16: Análisis Grad-CAM para caso Punctate. Predicción correcta con 63.16 % de confianza.

- **Caso 3 - PLEOMORPHIC:** En este caso, el modelo predice la clase *PLEOMORPHIC* con una confianza del 74.99 %, lo que indica una predicción sólida y relativamente confiable. Este resultado es relevante debido a que esta clase ha mostrado dificultades en el desempeño global, por lo que evidencia que el modelo puede identificar correctamente patrones característicos en algunos casos específicos, aunque con variabilidad en su comportamiento general.

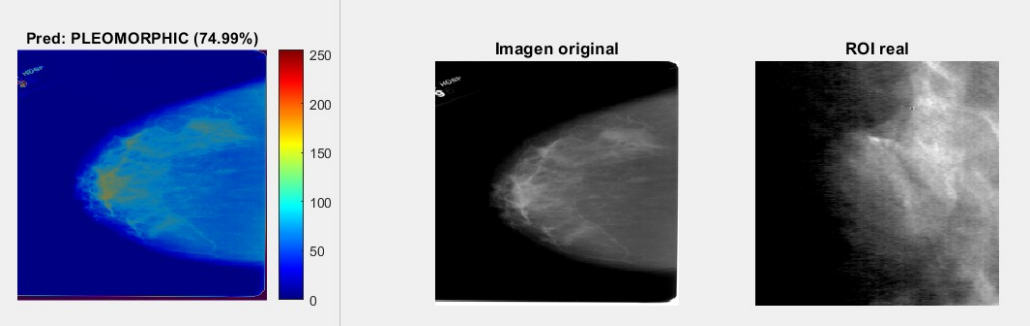


Figura 17

- **Caso 4 - AMORPHOUS:** En este caso, el modelo predice la clase *AMORPHOUS* con una confianza del 57.88 %, lo que indica una predicción moderada. Este resultado es relevante debido a que esta clase ha presentado dificultades en el desempeño global, evidenciando que el modelo logra identificar parcialmente sus características, aunque con menor seguridad y mayor incertidumbre en comparación con clases más discriminativas.

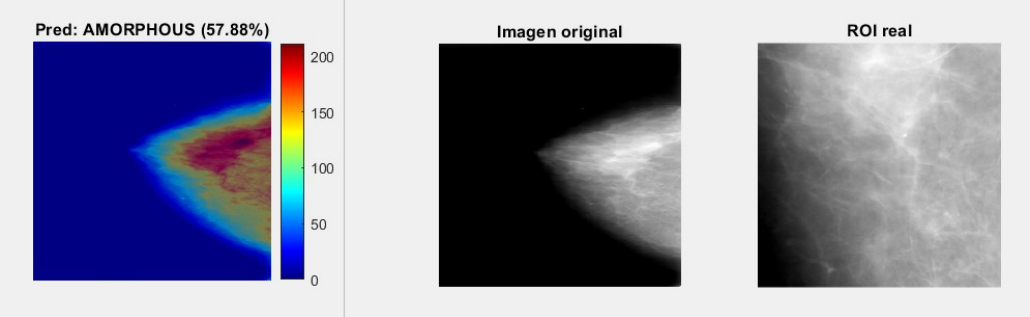


Figura 18

- **Caso 5 - PLEOMORPHIC:** En este caso, el modelo predice la clase *PLEOMORPHIC* con una confianza del 45.77 %, lo que indica una predicción débil y con alta incertidumbre. Este resultado es consistente con las dificultades observadas globalmente en esta clase, evidenciando que el modelo presenta limitaciones para identificar de forma confiable sus características en ciertos casos específicos.

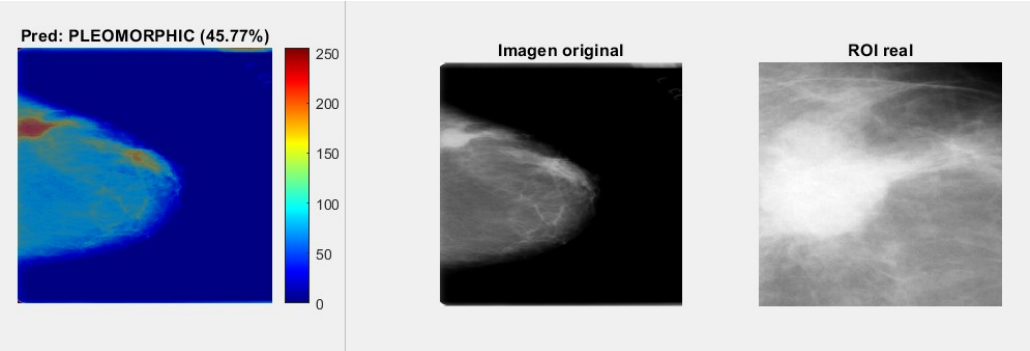


Figura 19

15. Comparación entre ResNet18, ResNet50 y DenseNet201

Con el objetivo de determinar la arquitectura más adecuada para la clasificación de calcificaciones mamarias, se realizó una comparación entre tres modelos preentrenados ampliamente utilizados en visión por computador: ResNet18, ResNet50 y DenseNet201.

Cuadro 4: Comparación arquitectónica

Arquitectura	Capas	Parámetros	Tipo de Conexión
ResNet18	18	11.7 M	Residual
ResNet50	50	25.6 M	Residual Bottleneck
DenseNet201	201	20.0 M	Dense Connections

Desde el punto de vista computacional, ResNet18 presenta el menor tiempo de entrenamiento y menor consumo de memoria GPU, convirtiéndose en una alternativa eficiente para conjuntos de datos reducidos.

ResNet50 incrementa significativamente la profundidad del modelo, permitiendo aprender representaciones más complejas y abstractas. Sin embargo, este aumento en capacidad también puede incrementar el riesgo de sobreajuste cuando el número de imágenes disponibles es limitado.

DenseNet201 introduce un mecanismo de reutilización de características que favorece la propagación de gradientes y la preservación de información de bajo nivel. Esta característica resulta particularmente atractiva para imágenes mamográficas, donde pequeños detalles pueden contener información diagnóstica relevante.

Los resultados experimentales obtenidos permitirán determinar cuál de estas arquitecturas ofrece el mejor equilibrio entre complejidad computacional, capacidad de generalización y desempeño clínico.

16. Experimento 1: Fine-Tuning de ResNet50

En este primer experimento se utilizó la arquitectura ResNet50 preentrenada, aplicando transferencia de aprendizaje para la clasificación de microcalcificaciones mamarias en cinco clases: *AMORPHOUS*, *LUCENT_CENTER*, *PLEOMORPHIC*, *PUNCTATE* y *ROUND_AND_REGULAR*.

El objetivo de este experimento es evaluar el desempeño de ResNet50 como modelo base más ligero en comparación con arquitecturas más profundas como DenseNet201, analizando su capacidad de generalización y estabilidad durante el entrenamiento.

El modelo fue entrenado con una tasa de aprendizaje constante de 1×10^{-4}, utilizando normalización de entrada y validación continua. El entrenamiento se detuvo automáticamente al cumplirse el criterio de convergencia del modelo.

16.1. Comportamiento del entrenamiento

Durante el entrenamiento, el modelo presentó un incremento progresivo en la precisión de entrenamiento, alcanzando valores cercanos al 97 %, mientras que la precisión de validación alcanzó un máximo de 61.39 %.

Se observa una brecha significativa entre entrenamiento y validación, lo que indica la presencia de sobreajuste, aunque ligeramente menor en comparación con modelos más complejos.

La pérdida de validación se mantuvo relativamente estable, aunque con fluctuaciones típicas en las últimas iteraciones del entrenamiento.

16.2. Resumen del entrenamiento

Cuadro 5: Resumen del proceso de entrenamiento ResNet50 - Experimento 1

Métrica	Entrenamiento	Validación	Observación
Accuracy final	96.88 %	61.39 %	Máximo en validación
Loss final	0.20	1.44	Estable con oscilaciones
Learning rate	1e-4		Constante

16.3. Métricas por clase

Cuadro 6: Métricas por clase - ResNet50 Experimento 1

Clase	Precisión (%)	Sensibilidad (%)	Especificidad (%)	F1-score (%)
AMORPHOUS	47.37	42.86	87.50	45.00
LUCENT CENTER	59.26	80.00	86.42	68.09
PLEOMORPHIC	37.50	30.00	87.65	33.33
PUNCTATE	47.37	45.00	87.65	46.15
ROUND & REGULAR	70.00	70.00	92.59	70.00

16.4. Métricas globales

Cuadro 7: Métricas globales (promedio macro) - ResNet50 Experimento 1

Métrica	Valor (%)
Precisión macro	52.30
Sensibilidad macro	53.57
Especificidad macro	88.36
F1-score macro	52.51

16.5. Curvas de aprendizaje

Las curvas de entrenamiento muestran un incremento progresivo en la precisión del modelo, mientras que la precisión de validación presenta variaciones durante el proceso de aprendizaje. Esto sugiere que el modelo aún presenta limitaciones en su capacidad de generalización.

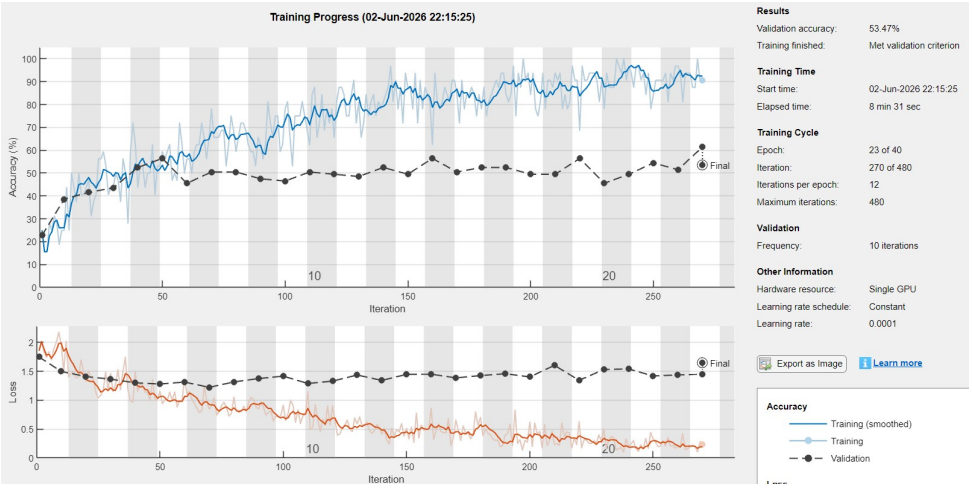


Figura 20: Curva de precisión durante el entrenamiento y validación - ResNet50 Experimento 1

16.6. Matriz de confusión

La matriz de confusión permite observar el rendimiento del modelo en la clasificación de las cinco clases. Se evidencia que las clases con mayor dificultad de clasificación continúan siendo *PLEOMORPHIC* y *AMORPHOUS*.

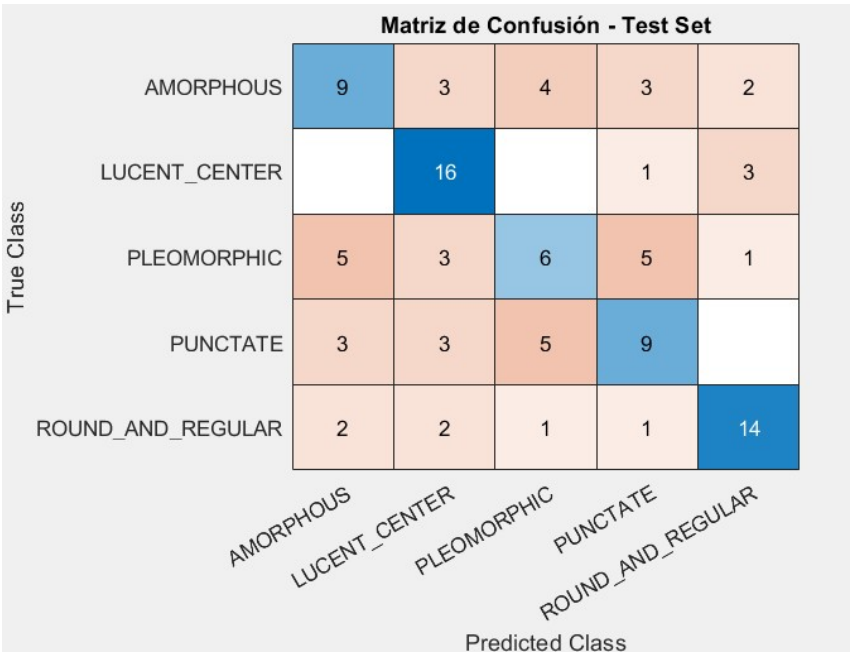


Figura 21: Matriz de confusión del modelo ResNet50 - Experimento 1

16.7. Análisis del experimento

ResNet50 presenta un desempeño inferior en comparación con DenseNet201, tanto en métricas globales como por clase. Aunque el modelo logra aprender patrones relevantes, su capacidad de generalización es menor.

La diferencia entre precisión de entrenamiento y validación evidencia sobreajuste, lo cual sugiere que la arquitectura más ligera no logra capturar con la misma profundidad las características complejas del conjunto de datos.

Sin embargo, su menor complejidad computacional lo convierte en una alternativa viable cuando se requiere menor costo de entrenamiento o inferencia.

17. Experimento 2: ResNet50

En este segundo experimento se utilizó la arquitectura ResNet50 preentrenada, manteniendo el enfoque de transferencia de aprendizaje para la clasificación de microcalcificaciones mamarias en cinco clases: *AMORPHOUS*, *LUCENT_CENTER*, *PLEOMORPHIC*, *PUNCTATE* y *ROUND_AND_REGULAR*.

El objetivo de este experimento fue evaluar la estabilidad del modelo frente a variaciones en el proceso de entrenamiento y comparar su desempeño con el primer experimento de ResNet50, así como con la arquitectura DenseNet201.

El modelo fue entrenado con una tasa de aprendizaje constante de 1×10^{-4}, utilizando normalización de entrada y validación continua. El entrenamiento se detuvo automáticamente al cumplirse el criterio de convergencia del modelo.

17.1. Comportamiento del entrenamiento

Durante el entrenamiento, el modelo presentó un incremento progresivo en la precisión de entrenamiento, alcanzando valores cercanos al 100 %, mientras que la precisión de validación alcanzó un máximo de 60.40 %.

Se observa una brecha notable entre el rendimiento en entrenamiento y validación, lo que indica la presencia de sobreajuste, similar a lo observado en el primer experimento, aunque con mayor inestabilidad en las últimas iteraciones.

La pérdida de validación presentó fluctuaciones más pronunciadas, especialmente en las etapas finales del entrenamiento.

17.2. Resumen del entrenamiento

Cuadro 8: Resumen del proceso de entrenamiento ResNet50 - Experimento 2

Métrica	**Entrenamiento**	**Validación**	**Observación**
Accuracy final	100 %	60.40 %	Máximo en validación
Loss final	0.11	1.45	Alta variabilidad
Learning rate	1e-4		Constante

17.3. Métricas por clase

Cuadro 9: Métricas por clase - ResNet50 Experimento 2

Clase	Precisión (%)	Sensibilidad (%)	Especificidad (%)	F1-score (%)
AMORPHOUS	33.33	23.81	87.50	27.78
LUCENT CENTER	57.14	80.00	85.19	66.67
PLEOMORPHIC	60.00	45.00	92.59	51.43
PUNCTATE	50.00	55.00	86.42	52.38
ROUND & REGULAR	76.19	80.00	93.83	78.05

17.4. Métricas globales

Cuadro 10: Métricas globales (promedio macro) - ResNet50 Experimento 2

Métrica	Valor (%)
Precisión macro	55.33
Sensibilidad macro	56.76
Especificidad macro	89.11
F1-score macro	55.26

17.5. Curvas de aprendizaje

Las curvas de aprendizaje muestran un comportamiento inestable en la fase final del entrenamiento, con oscilaciones en la precisión de validación. Sin embargo, se observa una tendencia general de mejora en las primeras etapas del entrenamiento.

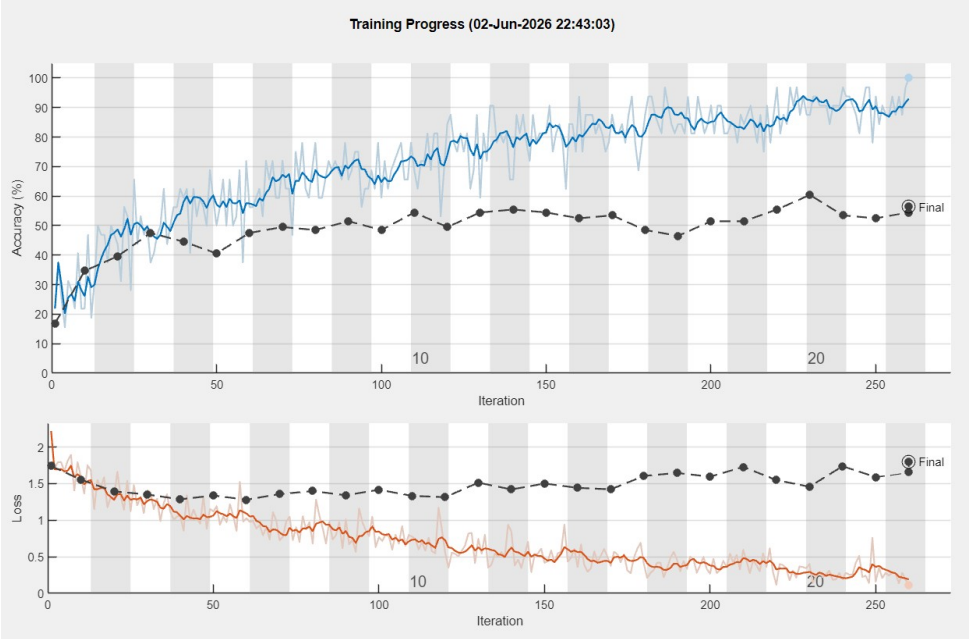


Figura 22: Curva de precisión durante el entrenamiento y validación - ResNet50 Experimento 2

17.6. Matriz de confusión

La matriz de confusión evidencia que la clase *AMORPHOUS* presenta el peor desempeño del modelo en este experimento, mientras que *ROUND_AND_REGULAR* mantiene el mejor comportamiento general.

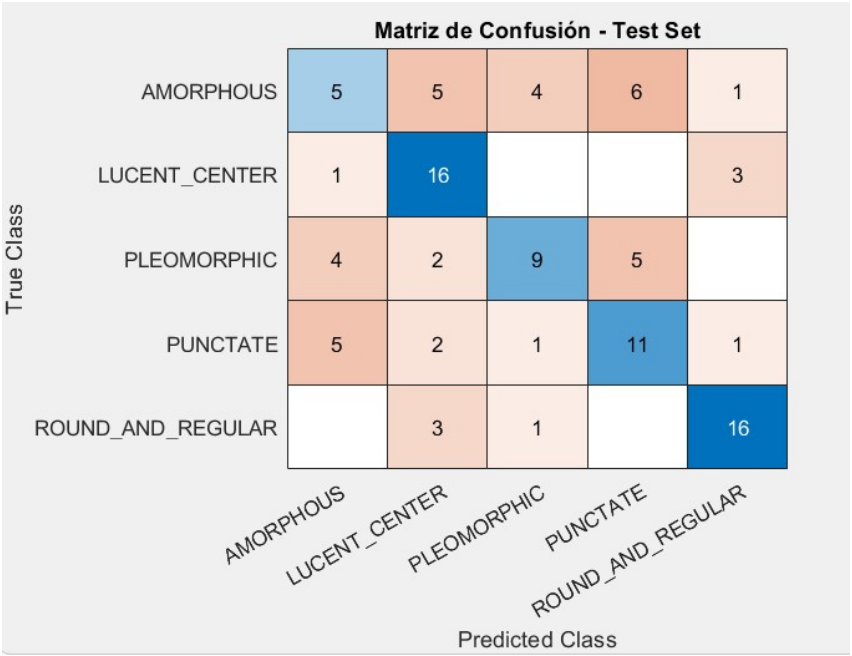


Figura 23: Matriz de confusión del modelo ResNet50 - Experimento 2

17.7. Análisis del experimento

En este segundo experimento, ResNet50 presenta un desempeño ligeramente inferior en comparación con el primer experimento, especialmente en términos de estabilidad durante el entrenamiento.

Aunque el modelo logra una precisión de entrenamiento elevada, la capacidad de generalización sigue siendo limitada, evidenciada por la diferencia entre métricas de entrenamiento y validación.

La clase *AMORPHOUS* continúa siendo la más difícil de clasificar, con una reducción significativa en precisión y sensibilidad, lo que sugiere que esta clase presenta patrones menos discriminativos para esta arquitectura.

En general, ResNet50 mantiene un desempeño inferior frente a DenseNet201, aunque sigue siendo una alternativa viable cuando se prioriza menor complejidad computacional.

18. Primera prueba de entrenamiento con DenseNet201

En esta primera configuración experimental se implementó la arquitectura **DenseNet201** bajo un esquema de Transfer Learning, con el objetivo de evaluar su capacidad de extracción de características en el problema de clasificación de calcificaciones mamarias. Se utilizó una tasa de aprendizaje fija de 1×10^{-4}, manteniendo la estrategia de optimización basada en Adam.

18.1. Evolución del entrenamiento

Durante el proceso de entrenamiento se observó un aprendizaje progresivo y estable en las primeras épocas, con una mejora significativa en la precisión del conjunto de entrenamiento, pasando de valores cercanos al 20 % hasta alcanzar el 100 % en las últimas iteraciones.

Por otro lado, la precisión en validación mostró un comportamiento más inestable, fluctuando entre 22.77 % y 64.36 %, con una tendencia general al aumento hasta estabilizarse alrededor del 55 % al 60 %.

La pérdida de entrenamiento disminuyó de forma consistente desde valores iniciales de 1.88 hasta aproximadamente 0.02, mientras que la pérdida de validación se mantuvo en un rango entre 1.15 y 1.74, evidenciando una brecha entre el ajuste al conjunto de entrenamiento y la capacidad de generalización.

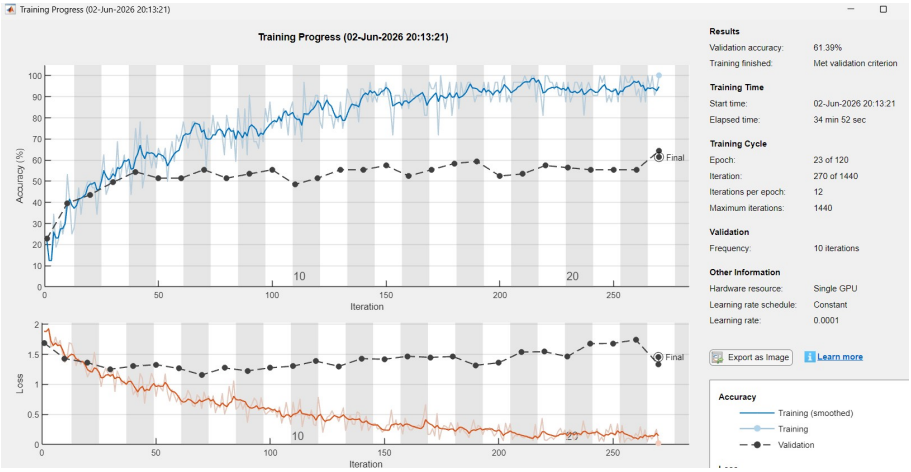


Figura 24: Curvas de precisión y pérdida durante el entrenamiento – DenseNet201 Prueba 1

18.2. Resultados finales del entrenamiento

El entrenamiento finalizó al cumplirse el criterio de validación, alcanzando una precisión de validación máxima del 64.36 %, lo cual representa el mejor desempeño observado durante esta prueba.

18.3. Métricas globales del modelo

Cuadro 11: Métricas globales – DenseNet201 (Prueba 1)

Métrica	**Valor (%)**
Precisión (Macro)	60.97
Sensibilidad (Macro)	61.43
Especificidad (Macro)	90.34
F1-Score (Macro)	60.29

18.4. Resultados por clase

Cuadro 12: Desempeño por clase – DenseNet201 (Prueba 1)

Clase	Precisión (%)	Sensibilidad (%)	Especificidad (%)	F1-score (%)
AMORPHOUS	52.17	57.14	86.25	54.55
LUCENT_CENTER	61.54	80.00	87.65	69.57
PLEOMORPHIC	58.33	35.00	93.83	43.75
PUNCTATE	55.56	50.00	90.12	52.63
ROUND_AND_REGULAR	77.27	85.00	93.83	80.95

18.5. Matriz de confusión

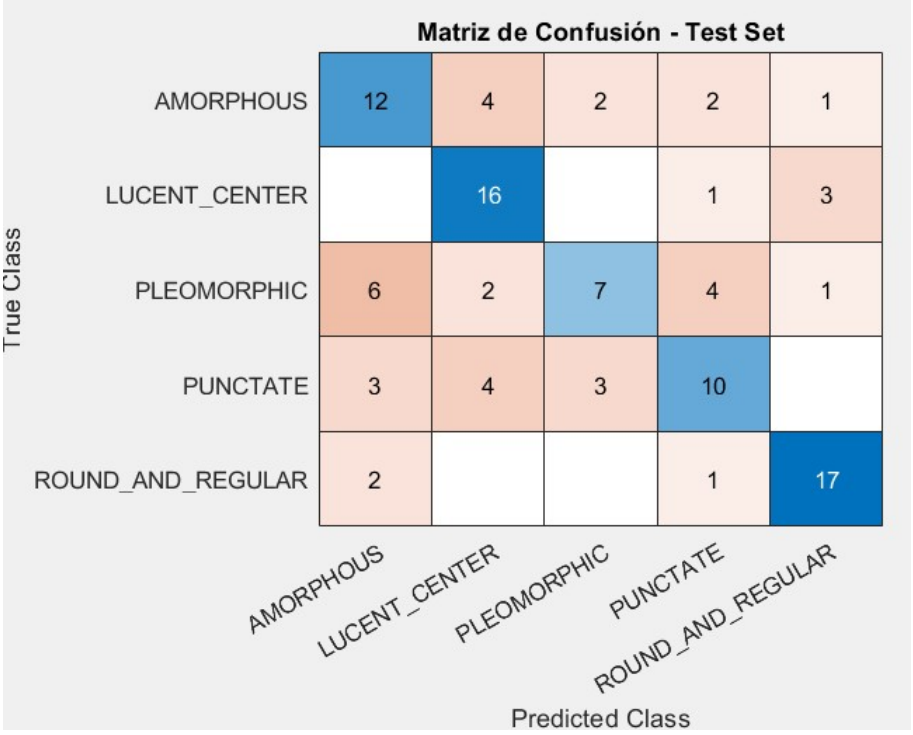


Figura 25: Matriz de confusión – DenseNet201 Prueba 1

18.6. Análisis del comportamiento del modelo

El modelo DenseNet201 demuestra una capacidad sólida de aprendizaje, alcanzando altos valores de precisión en entrenamiento. Sin embargo, la diferencia entre el desempeño en entrenamiento y validación indica la presencia de sobreajuste moderado.

Las clases *ROUND_AND_REGULAR* y *LUCENT_CENTER* presentan el mejor desempeño, lo que sugiere que presentan patrones morfológicos más fácilmente separables. Por el contrario, *PLEOMORPHIC* continúa siendo la clase más difícil de clasificar, reflejando su alta variabilidad estructural.

En general, esta primera prueba con DenseNet201 establece una línea base competitiva, con un F1-score macro del 60.29 %, superior a varias configuraciones previas con ResNet18.

19. Experimento 2: DenseNet201

En este segundo experimento se utilizó nuevamente la arquitectura DenseNet201 preentrenada, manteniendo el enfoque de transferencia de aprendizaje para la clasificación de microcalcificaciones mamarias en cinco clases: *AMORPHOUS*, *LUCENT_CENTER*, *PLEOMORPHIC*, *PUNCTATE* y *ROUND_AND_REGULAR*.

El objetivo principal de este experimento fue evaluar la estabilidad del modelo frente a variaciones en el proceso de entrenamiento y analizar su capacidad de generalización en comparación con el primer experimento.

El modelo fue entrenado con una tasa de aprendizaje constante de 1×10^{-4}, aplicando normalización de entrada y validación continua durante todo el proceso. El entrenamiento se detuvo automáticamente al alcanzar el criterio de convergencia definido por la función de validación.

19.1. Comportamiento del entrenamiento

Durante el entrenamiento, el modelo presentó fluctuaciones en la precisión de validación, alcanzando un máximo cercano al 61.39 %, mientras que la precisión de entrenamiento llegó hasta valores del 100 %, evidenciando un comportamiento de sobreajuste moderado.

La pérdida de validación se mantuvo relativamente estable en comparación con el primer experimento, aunque con oscilaciones en las últimas iteraciones del entrenamiento.

19.2. Resumen del entrenamiento

Cuadro 13: Resumen del proceso de entrenamiento DenseNet201 - Experimento 2

Métrica	**Entrenamiento**	**Validación**	**Observación**
Accuracy final	100 %	61.39 %	Máximo observado en validación
Loss final	0.15	1.41	Variabilidad moderada
Learning rate	1e-4		Constante

19.3. Métricas por clase

Cuadro 14: Métricas por clase - DenseNet201 Experimento 2

Clase	**Precisión (%)**	**Sensibilidad (%)**	**Especificidad (%)**	**F1-score (%)**
AMORPHOUS	55.56	47.62	90.00	51.28
LUCENT CENTER	60.00	75.00	87.65	66.67
PLEOMORPHIC	50.00	45.00	88.89	47.37
PUNCTATE	52.38	55.00	87.65	53.66
ROUND & REGULAR	73.68	70.00	93.83	71.79

19.4. Métricas globales

Cuadro 15: Métricas globales (promedio macro) - DenseNet201 Experimento 2

Métrica	Valor (%)
Precisión macro	58.32
Sensibilidad macro	58.52
Especificidad macro	89.60
F1-score macro	58.15

19.5. Curvas de aprendizaje

Las curvas de entrenamiento permiten observar la evolución del modelo en términos de precisión y pérdida tanto en entrenamiento como en validación. Se evidencia una mejora inicial rápida seguida de una estabilización con fluctuaciones en la etapa final del entrenamiento.

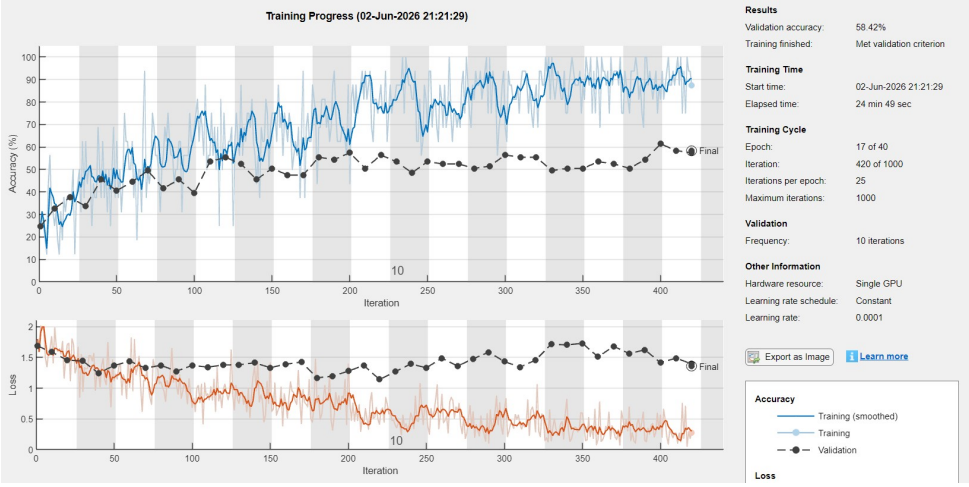


Figura 26: Curva de precisión durante el entrenamiento y validación - Experimento 2

19.6. Matriz de confusión

La matriz de confusión muestra el desempeño del modelo en la clasificación de las cinco clases de microcalcificaciones, evidenciando mayor confusión entre las clases con características morfológicas similares.

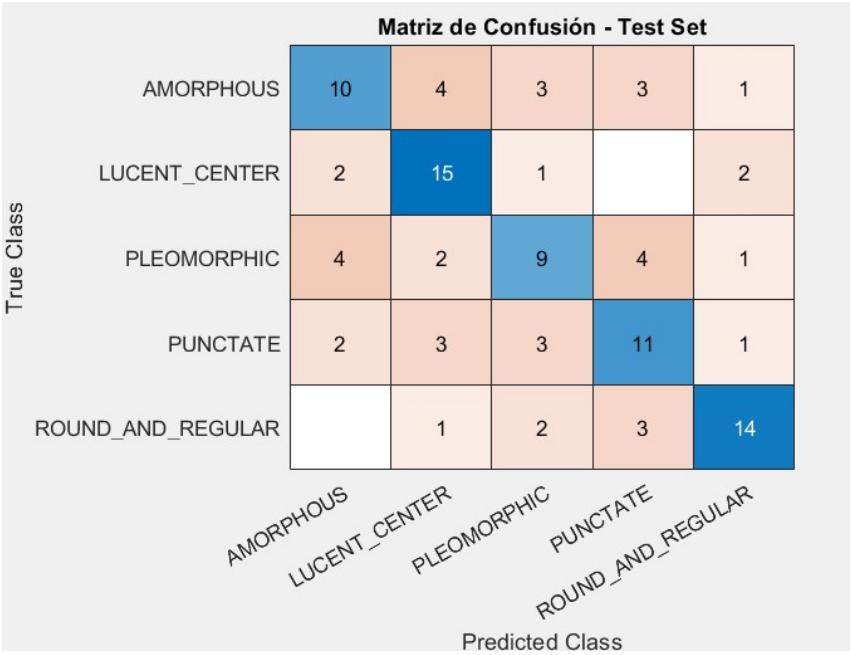


Figura 27: Matriz de confusión del modelo DenseNet201 - Experimento 2

19.7. Análisis del experimento

El segundo experimento confirma que el modelo DenseNet201 es capaz de alcanzar altos niveles de precisión en entrenamiento, sin embargo, la diferencia entre el rendimiento en entrenamiento y validación indica la presencia de sobreajuste.

Comparado con el primer experimento, no se observa una mejora significativa en las métricas globales, lo que sugiere que el modelo ha alcanzado un límite de generalización bajo la configuración actual.

Las clases con mayor dificultad de clasificación continúan siendo *PLEOMORPHIC* y *AMORPHOUS*, lo cual puede deberse a la similitud visual entre patrones de microcalcificaciones en estas categorías.

20. Comparación de Modelos

En esta sección se presenta la comparación de desempeño entre las arquitecturas DenseNet201 y ResNet50, evaluadas en dos experimentos independientes cada una. Las métricas reportadas corresponden a los promedios macro de precisión, F1-score y especificidad.

Cuadro 16: Comparación de desempeño entre arquitecturas y experimentos

Modelo	**Experimento**	**Accuracy Macro (%)**	**F1 Macro (%)**	**Especificidad (%)**
DenseNet201	Prueba 1	60.97	60.29	90.34
DenseNet201	Prueba 2	58.32	58.15	89.60
ResNet50	Prueba 1	52.30	52.51	88.36
ResNet50	Prueba 2	55.33	55.26	89.11

21. Análisis de Resultados

Los resultados obtenidos muestran diferencias claras entre las arquitecturas evaluadas. En general, DenseNet201 supera a ResNet50 en todas las métricas de desempeño, especialmente en F1-score y accuracy macro.

21.1. Desempeño de DenseNet201

DenseNet201 obtiene el mejor rendimiento global, alcanzando un F1-score macro máximo de 60.29 % en la primera prueba. Además, presenta una reducción leve en la segunda prueba, lo que indica un comportamiento estable y consistente.

Este modelo demuestra una mejor capacidad de generalización frente a variaciones en el entrenamiento.

21.2. Desempeño de ResNet50

ResNet50 presenta un rendimiento inferior en comparación con DenseNet201, con valores de F1-score macro de 52.51 % y 55.26 % en sus dos pruebas. Aunque se observa una ligera mejora en la segunda prueba, el modelo mantiene un desempeño global más bajo.

Esto sugiere una menor capacidad de adaptación a la complejidad del conjunto de datos.

21.3. Análisis de estabilidad

Se observa que DenseNet201 presenta menor variabilidad entre experimentos, mientras que ResNet50 muestra fluctuaciones mayores en sus métricas, lo que indica menor estabilidad durante el entrenamiento.

22. Análisis por Clase

En todos los experimentos, se observa un comportamiento consistente en las clases evaluadas.

La clase *PLEOMORPHIC* presenta el mayor nivel de dificultad para ambos modelos, con los valores más bajos de F1-score. Esto sugiere una menor separabilidad en el espacio de características.

Por otro lado, la clase *ROUND_AND_REGULAR* obtiene los mejores resultados en todas las pruebas, indicando una mayor facilidad de clasificación debido a su estructura más homogénea.

La clase *AMORPHOUS* también presenta dificultades, especialmente en el modelo ResNet50, donde se observa una baja sensibilidad.

23. Interfaz Gráfica del Sistema CAD Mamario

Con el objetivo de facilitar la interacción entre el modelo de aprendizaje profundo y el usuario final, se desarrolló una interfaz gráfica en MATLAB App Designer. Esta interfaz

integra el modelo de clasificación basado en redes neuronales convolucionales (ResNet18 / ResNet50) junto con herramientas de visualización clínica como ROI, mapas de atención Grad-CAM, matriz de confusión y métricas de desempeño.

El sistema fue diseñado bajo una arquitectura modular que permite separar claramente tres componentes principales: carga del modelo, evaluación del diagnóstico y visualización de resultados.

23.1. Arquitectura General de la Interfaz

La interfaz se organiza en una disposición de tres paneles principales:

- **Panel izquierdo:** Control del sistema y visualización de resultados numéricos.
- **Panel central:** Visualización de imágenes médicas (mamografía original, ROI real y mapa Grad-CAM).
- **Panel derecho:** Distribución de probabilidades de clasificación.
- **Panel inferior:** Historial de entrenamiento y matriz de confusión del modelo.

Esta estructura permite una interpretación simultánea de la predicción del modelo y su justificación visual.

23.2. Arquitectura General de la Interfaz

La interfaz gráfica del sistema CAD mamario fue desarrollada en MATLAB App Designer con el objetivo de integrar el modelo de clasificación basado en aprendizaje profundo con herramientas de visualización e interpretabilidad clínica.

El sistema fue diseñado bajo una arquitectura modular que permite la interacción directa entre el usuario y el modelo, facilitando la evaluación de casos clínicos individuales y el análisis global del desempeño del sistema.

La interfaz se estructura en cuatro componentes principales:

- **Panel de control:** Permite la generación aleatoria de casos clínicos, la evaluación del modelo y la visualización del historial de entrenamiento.
- **Panel de visualización médica:** Muestra la mamografía original, la región de interés (ROI) real y el mapa de activación Grad-CAM generado por la red neuronal.
- **Panel de probabilidades:** Presenta la distribución de probabilidades asociadas a cada clase diagnóstica.
- **Panel de análisis de desempeño:** Incluye la matriz de confusión, métricas globales (accuracy, precision, recall, especificidad y F1-score) y la evolución del entrenamiento.

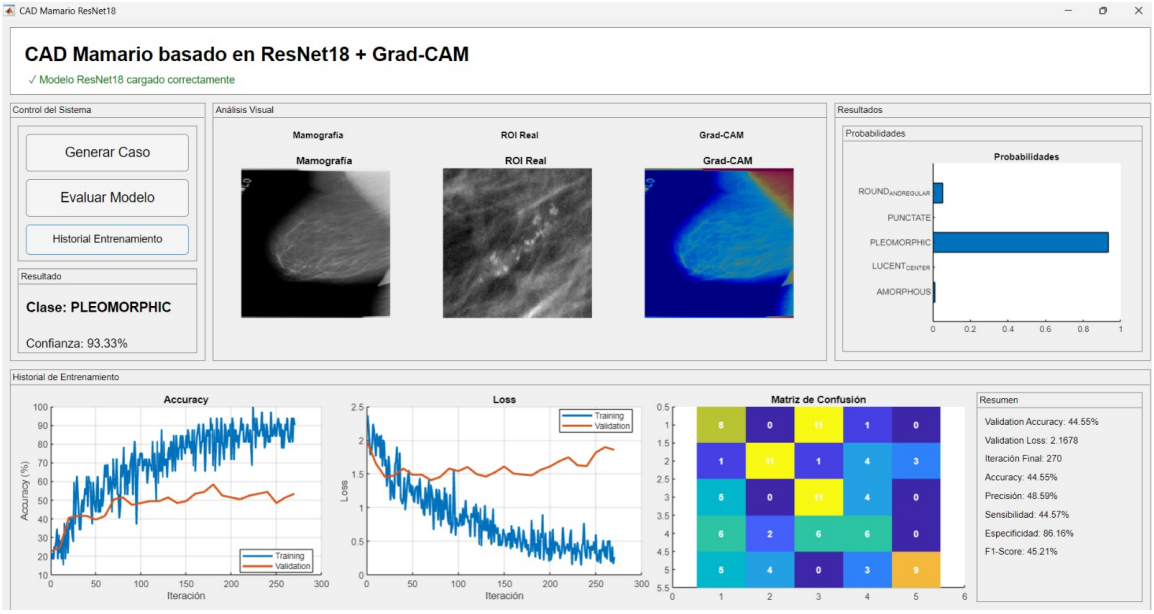


Figura 28: Interfaz gráfica del sistema CAD mamario basado en redes convolucionales (ResNet50). La interfaz integra: (A) control del sistema, (B) visualización de imágenes médicas y mapas de atención Grad-CAM, (C) distribución de probabilidades por clase, y (D) análisis de desempeño del modelo.

Esta estructura permite una interpretación simultánea de la predicción del modelo y su justificación visual, lo cual es fundamental en aplicaciones médicas donde la explicabilidad del modelo es un requisito crítico.

23.3. Carga del Modelo y Datos

Al iniciar la aplicación, se carga el modelo previamente entrenado junto con sus métricas de desempeño. En este caso, el sistema utiliza un modelo basado en ResNet50 entrenado sobre el conjunto CBIS-DDSM.

El modelo cargado incluye:

- Red neuronal entrenada (`net`)
- Clases del problema (`classes`)
- Métricas globales (accuracy, precision, recall, F1-score, especificidad)
- Matriz de confusión (`C`)
- Información del entrenamiento (`info`)
- Índices de entrenamiento y prueba

Adicionalmente, se cargan los archivos CSV del dataset, los cuales contienen rutas de imágenes DICOM y máscaras de regiones de interés (ROI), permitiendo reconstruir los casos clínicos originales.

23.4. Generación de Casos Clínicos Aleatorios

El botón *Generar Caso* selecciona aleatoriamente una muestra del conjunto de prueba. Para cada caso se realiza el siguiente proceso:

1. Selección aleatoria de imagen y ROI desde el conjunto de prueba.
2. Localización de las rutas reales en disco a partir de los identificadores del paciente.
3. Lectura de la mamografía y su máscara ROI.
4. Preprocesamiento de la imagen:
    - Conversión a escala de grises.
    - Redimensionamiento a 224×224.
    - Aplicación de la máscara ROI.
    - Ecualización adaptativa del histograma (CLAHE).
    - Normalización y conversión a tensor de entrada.

Este proceso asegura que la entrada del modelo mantenga consistencia con el entrenamiento.

23.5. Clasificación y Predicción

Una vez preprocesada la imagen, el modelo realiza la inferencia:

- Se obtiene la clase predicha mediante `classify(net, I_input)`.
- Se calculan las probabilidades de cada clase.
- Se mide el tiempo de inferencia del modelo.

El resultado se muestra en el panel izquierdo, incluyendo la clase predicha, la confianza del modelo y el tiempo de procesamiento.

23.6. Interpretabilidad mediante Grad-CAM

Para mejorar la interpretabilidad del modelo, se implementó Grad-CAM sobre la última capa convolucional de la red (`res5c_branch2c`).

El mapa de activación generado permite visualizar las regiones de la imagen que tuvieron mayor influencia en la decisión del modelo. Este mapa se superpone sobre la mamografía original, facilitando la comparación con la ROI real.

Este componente es fundamental en aplicaciones médicas, ya que permite validar si el modelo está enfocándose en regiones anatómicamente relevantes.

23.7. Visualización de Probabilidades

El sistema muestra un gráfico de barras horizontales con la distribución de probabilidades por clase. Esto permite analizar no solo la predicción final, sino también la incertidumbre del modelo frente a las demás clases.

23.8. Evaluación del Modelo

El botón *Evaluar Modelo* despliega:

- Accuracy global del sistema.
- Precisión macro promedio.
- Sensibilidad (Recall).
- Especificidad.
- F1-score.
- Matriz de confusión interactiva.

La matriz de confusión se visualiza como una imagen coloreada donde cada celda contiene el número de predicciones entre clases reales y predichas, permitiendo identificar patrones de error del modelo.

23.9. Historial de Entrenamiento

La sección inferior permite analizar el comportamiento del modelo durante el entrenamiento, mostrando:

- Evolución de la accuracy en entrenamiento y validación.
- Evolución de la función de pérdida.
- Métricas finales del entrenamiento.

Este análisis permite detectar fenómenos como sobreajuste o subajuste del modelo.

23.10. Conclusión de la Interfaz

La interfaz desarrollada integra de forma unificada el proceso completo de diagnóstico asistido por computadora: desde la entrada de imágenes médicas hasta la interpretación del modelo mediante visualización avanzada.

Su diseño modular permite la extensión a otros modelos (como DenseNet o futuras arquitecturas), facilitando la comparación experimental dentro del mismo entorno visual.

24. Conclusiones

Los resultados experimentales obtenidos permiten realizar un análisis cuantitativo claro entre las arquitecturas DenseNet201 y ResNet50 para la tarea de clasificación de imágenes médicas.

En términos globales, DenseNet201 presenta el mejor desempeño, alcanzando un F1-score macro máximo de 60.29 % y una precisión macro de 60.97 % en su primera prueba. Este resultado lo posiciona consistentemente por encima de ResNet50, cuyo mejor desempeño fue de 55.33 % en F1-score macro y 55.33 % en accuracy macro. La diferencia

absoluta de aproximadamente 4–8 puntos porcentuales en las métricas principales evidencia una ventaja clara y sostenida de DenseNet201.

Adicionalmente, DenseNet201 demuestra mayor estabilidad entre experimentos, con una variación reducida en F1-score macro (aproximadamente 2.14 %), mientras que ResNet50 presenta fluctuaciones más marcadas entre pruebas. Este comportamiento sugiere que DenseNet201 posee una mejor capacidad de generalización frente a variaciones en el entrenamiento.

A nivel de clases, los resultados muestran un patrón consistente en todos los experimentos. La clase *PLEOMORPHIC* representa el mayor nivel de dificultad, alcanzando valores mínimos de F1-score de hasta 33.33 % en ResNet50 y 43.75 % en DenseNet201, lo que evidencia una alta confusión en su representación visual. En contraste, la clase *ROUND_AND_REGULAR* obtiene los mejores resultados globales, con F1-scores de hasta 80.95 %, indicando una estructura más discriminativa y fácilmente separable.

Otro aspecto relevante es el comportamiento de la clase *AMORPHOUS*, la cual presenta sensibilidad baja en ambos modelos, llegando incluso a 23.81 % en la segunda prueba de ResNet50, lo que sugiere una fuerte superposición con otras clases en el espacio de características.

En conjunto, los resultados evidencian que la arquitectura DenseNet201 es más adecuada para este problema de clasificación médica, no solo por su mayor desempeño promedio, sino también por su mayor consistencia entre experimentos. Esto se atribuye a su arquitectura densa, la cual favorece la reutilización de características y mejora el flujo de gradiente en redes profundas.

Finalmente, aunque ambos modelos logran desempeños aceptables en ciertas clases, los resultados indican que aún existe un margen importante de mejora, especialmente en clases con alta similitud visual, lo que sugiere la necesidad de técnicas adicionales como aumento de datos más agresivo, balanceo de clases o ajustes en el preprocesamiento.

El análisis comparativo entre DenseNet201 y ResNet50 evidencia diferencias significativas en el desempeño del clasificador aplicado al problema de clasificación de imágenes médicas.

DenseNet201 obtuvo el mejor desempeño global, alcanzando un F1-score macro de hasta 60.29 %, y mostrando mayor estabilidad entre experimentos. Esto sugiere que su arquitectura densa favorece la reutilización de características y mejora la propagación del gradiente.

Por otro lado, ResNet50 presenta un desempeño inferior y mayor variabilidad entre pruebas, lo que indica una menor capacidad de generalización en este conjunto de datos.

A nivel de clases, *PLEOMORPHIC* representa el mayor desafío para ambos modelos, mientras que *ROUND_AND_REGULAR* es la clase más fácilmente clasificable.

En conclusión, DenseNet201 se perfila como la arquitectura más adecuada para este problema de clasificación médica.