Sistema CAD para Clasificación de Lesiones Mamarias usando Deep Learning

Juan Pablo Rojas y Kevin Gualteros Jimenez

Inteligencia computacional II

5 de junio de 2026

Problema de Investigación

- El cáncer de mama es una de las principales causas de mortalidad femenina.
- Las microcalcificaciones son uno de los biomarcadores más importantes para su detección temprana.
- La clasificación manual depende de la experiencia del radiólogo.
- Existe alta similitud visual entre diferentes tipos de calcificaciones.
- Se propone un sistema basado en Deep Learning para automatizar su clasificación.

Objetivo General

Desarrollar un sistema de clasificación automática de calcificaciones mamarias utilizando:

- Transfer Learning.
- Redes neuronales convolucionales.
- Base de datos CBIS-DDSM.
- Técnicas de balanceo y aumento de datos.
- Métricas clínicas de evaluación.

Clasificación de cinco categorías:

1. Amorphous
2. Lucent Center
3. Pleomorphic
4. Punctate
5. Round and Regular

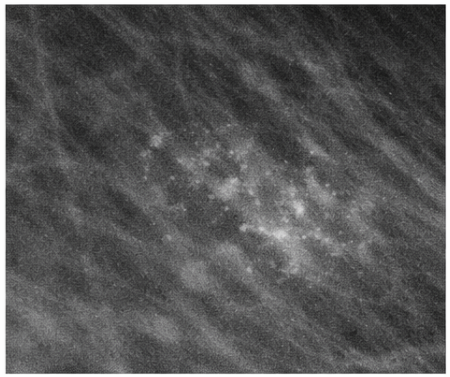
Base de Datos CBIS-DDSM

- Dataset público para investigación en cáncer de mama.
- Contiene mamografías digitalizadas.
- Incluye máscaras ROI.
- Incluye etiquetas clínicas.
- Archivos CSV para descripción de casos.

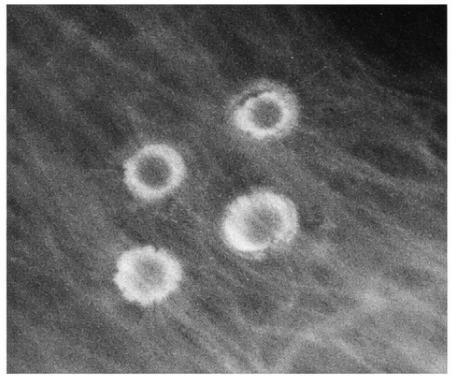
Ventajas

- Amplio uso en investigación.
- Datos etiquetados por especialistas.
- Disponibilidad de regiones de interés.

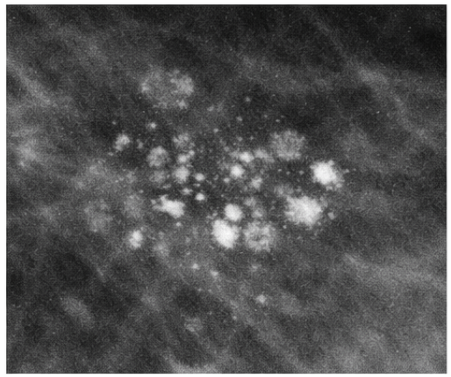
Tipos de Calcificaciones



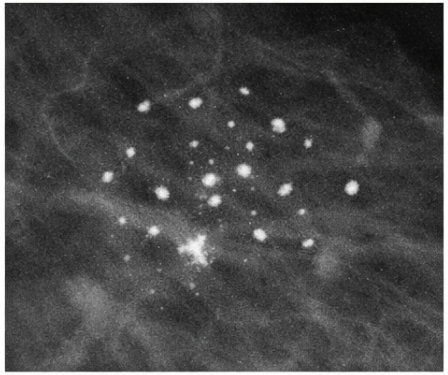
Amorphous



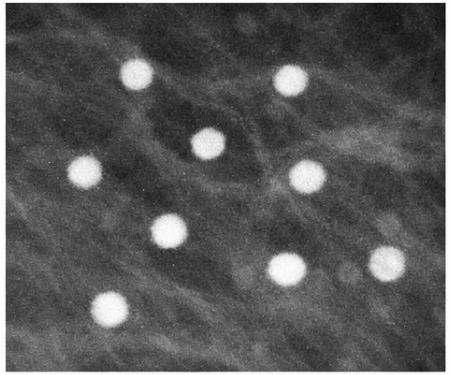
Lucent Center



Pleomorphic



Punctate



Round & Regular

Pipeline del Sistema Propuesto

- Adquisición de datos CBIS-DDSM.
- Extracción de mamografías y máscaras ROI.
- Preprocesamiento y normalización.
- Balanceo y aumento de datos.
- Entrenamiento mediante Transfer Learning.
- Clasificación automática.
- Evaluación mediante métricas clínicas.
- Interpretabilidad mediante Grad-CAM.
- Integración en sistema CAD.

Distribución Original del Dataset

Clase	Cantidad
Amorphous	153
Lucent Center	101
Pleomorphic	693
Punctate	150
Round and Regular	126

Problema identificado:

Desbalance severo

La clase Pleomorphic representa aproximadamente el 45 % del dataset.

Balanceo de Clases

Clase	Cantidad
Amorphous	153
Lucent Center	101
Pleomorphic	170
Punctate	150
Round and Regular	126

Resultado:

700 imágenes balanceadas

Beneficio:

- Reduce sesgo del modelo.
- Igual representación de todas las clases.

Preprocesamiento

1. Conversión a escala de grises.
2. Redimensionamiento a 224x224.
3. Aplicación de ROI.
4. Atenuación del fondo.
5. Ecualización adaptativa.
6. Conversión a 3 canales.

Objetivo

Resaltar únicamente la región patológica y reducir el ruido del tejido sano.

Data Augmentation

Transformaciones implementadas:

- Reflexión horizontal.
- Reflexión vertical.
- Traslaciones.
- Escalamiento.

Beneficios:

- Mayor capacidad de generalización.
- Menor sobreajuste.
- Incremento virtual del dataset.

Transfer Learning con ResNet18

Características:

- Red preentrenada en ImageNet.
- Conexiones residuales.
- 18 capas profundas.
- Uso de 11 millones de parámetros.

Modificaciones Realizadas

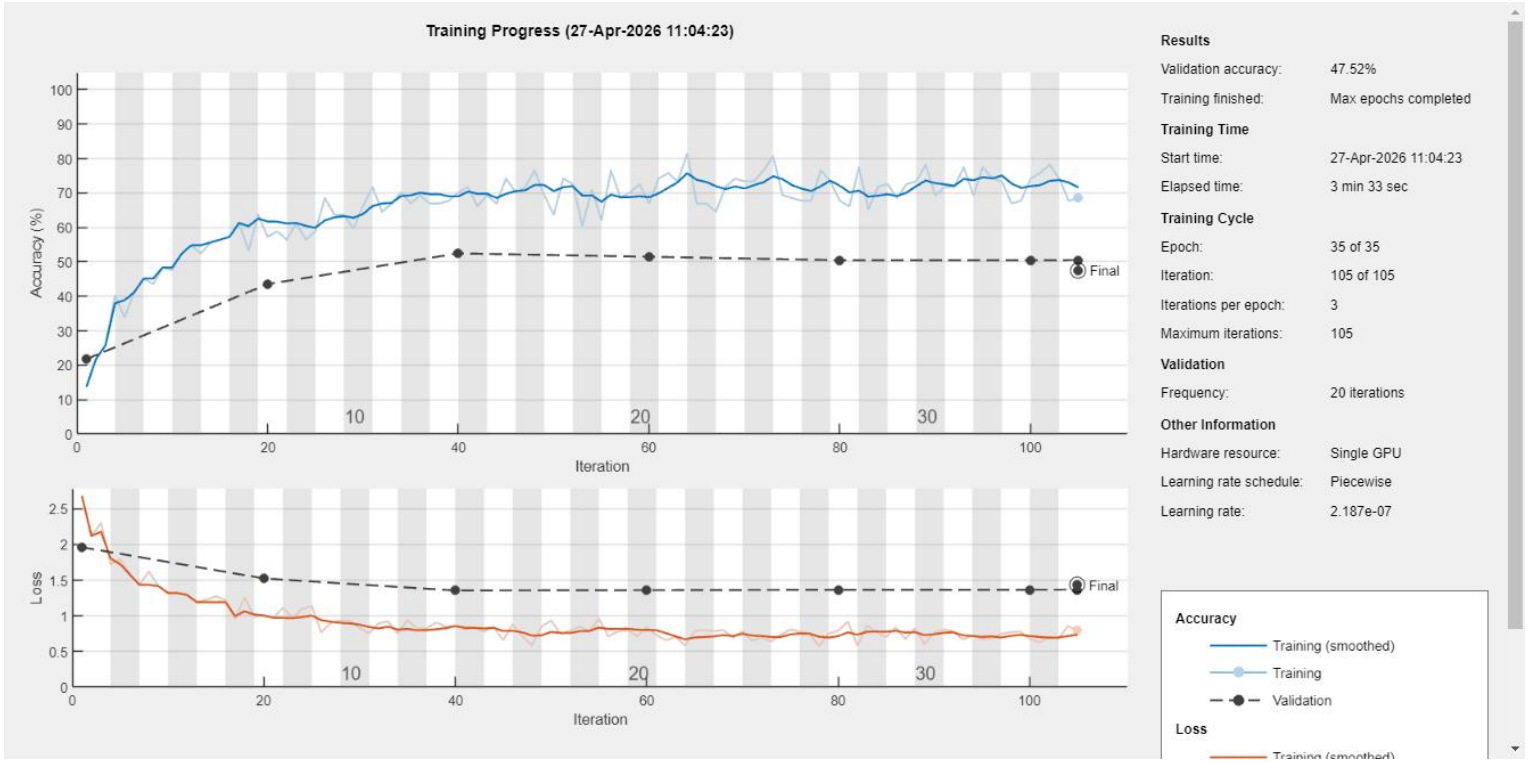
Se reemplazó la capa final por:

- Dropout
- Fully Connected Layer
- Softmax
- Classification Layer

Configuración:

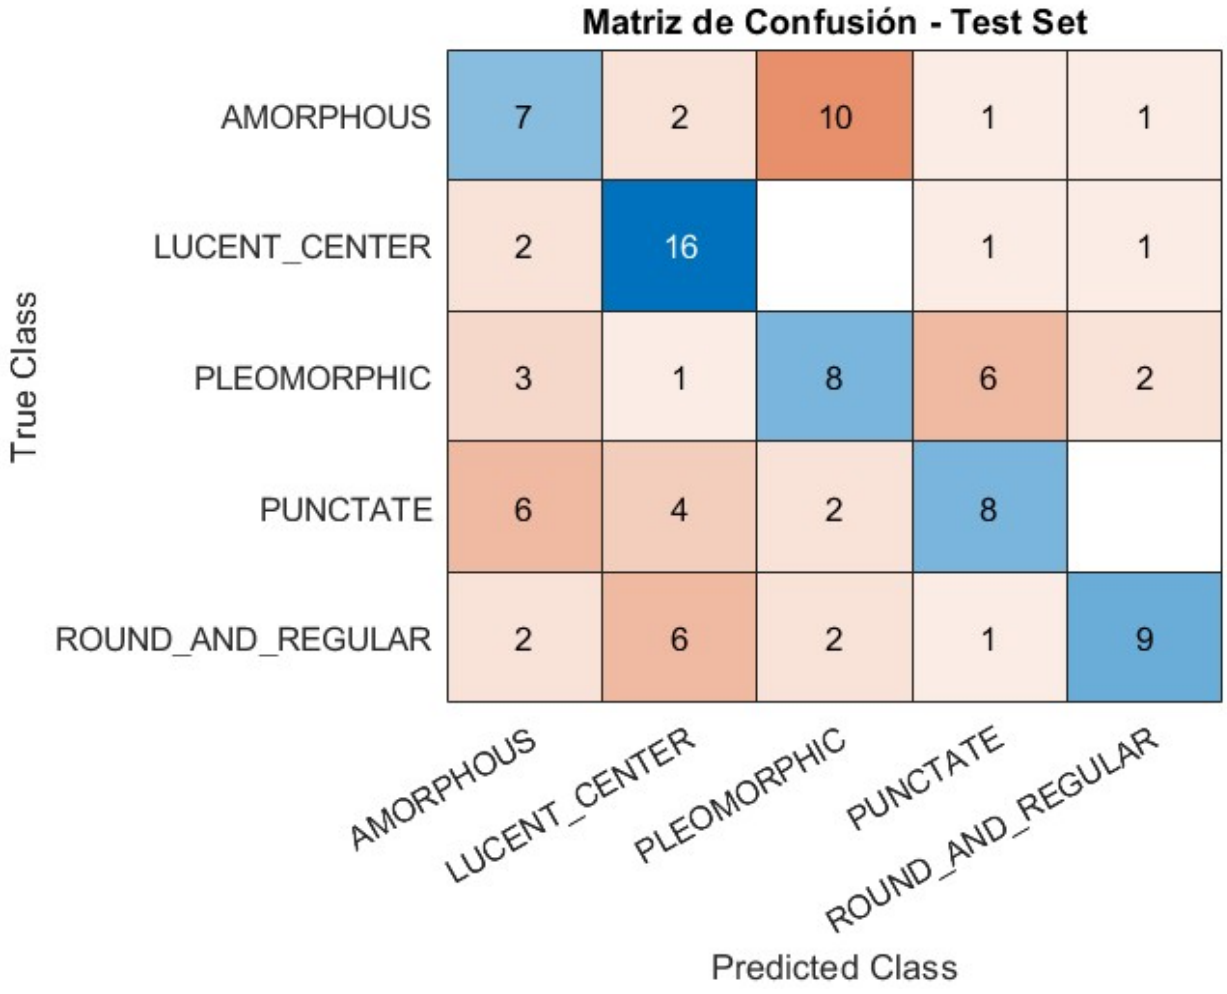
- Adam
- Uso de GPU para entrenamiento
- Learning Rate 1e-4
- MiniBatch = 32
- 40 épocas

Curvas de Entrenamiento



- Accuracy entrenamiento: 74.19 %
- Accuracy validación: 47.52 %

Matriz de Confusión



Métricas Obtenidas

Métrica	Valor (%)
Precisión	48.56
Recall	47.67
Especificidad	86.87
F1 Score	47.07

Objetivo del entregable 2

- Desarrollar un sistema CAD basado en Deep Learning.
- Clasificar 5 tipos de calcificaciones mamarias.
- Evaluar arquitecturas: ResNet50 y DenseNet201.
- Implementar una interfaz interactiva con interpretabilidad (Grad-CAM).

Arquitectura ResNet50

Residual Network (ResNet50)

- Red neuronal convolucional profunda
- Posee aproximadamente **25.6 millones de parámetros** distribuidos en 50 capas entrenables.
- Utiliza conexiones residuales (*Skip Connections*) que permiten el flujo directo de información entre capas.
- Reduce el problema de **Vanishing Gradient**, facilitando el entrenamiento de redes profundas.
- Implementa bloques tipo **Bottleneck**:
  - Convolución 1×1
  - Convolución 3×3
  - Convolución 1×1
- Permite aprender características más complejas que ResNet18.
- Especialmente útil para detectar diferencias morfológicas sutiles entre calcificaciones mamarias.

Arquitectura DenseNet201

Dense Convolutional Network (DenseNet201)

- Red neuronal profunda
- Posee aproximadamente **20 millones de parámetros** distribuidos en 201 capas profundas.
- Cada capa recibe como entrada las salidas de todas las capas anteriores.
- Utiliza conexiones densas (*Dense Connections*) mediante concatenación de características.
- Ventajas principales:
  - Mejor flujo del gradiente.
  - Mayor reutilización de características.
  - Menor redundancia en el aprendizaje.
  - Mejor aprovechamiento de conjuntos de datos pequeños.
- Facilita la extracción simultánea de características de bajo y alto nivel.
- Ha demostrado excelentes resultados en problemas de clasificación médica y análisis de imágenes radiológicas.

Comparación de Arquitecturas

Característica	ResNet18	ResNet50	DenseNet201
Capas	18	50	201
Parámetros	11.7 M	25.6 M	20 M
Conexiones Residuales	Sí	Sí	No
Conexiones Densas	No	No	Sí
Complejidad	Baja	Media	Alta
Costo Computacional	Bajo	Medio	Alto

Hipótesis del proyecto

- ResNet18 proporciona un entrenamiento rápido y estable.
- ResNet50 incrementa la capacidad de representación.
- DenseNet201 maximiza la reutilización de características y podría ofrecer la mejor capacidad de generalización.

Experimentos Realizados

- 2 pruebas con ResNet50
- 2 pruebas con DenseNet201
- Dataset aumentado y configuración base
- Learning rate: 1×10^{-4}

Experimentos Realizados

- Primera prueba con ResNet50

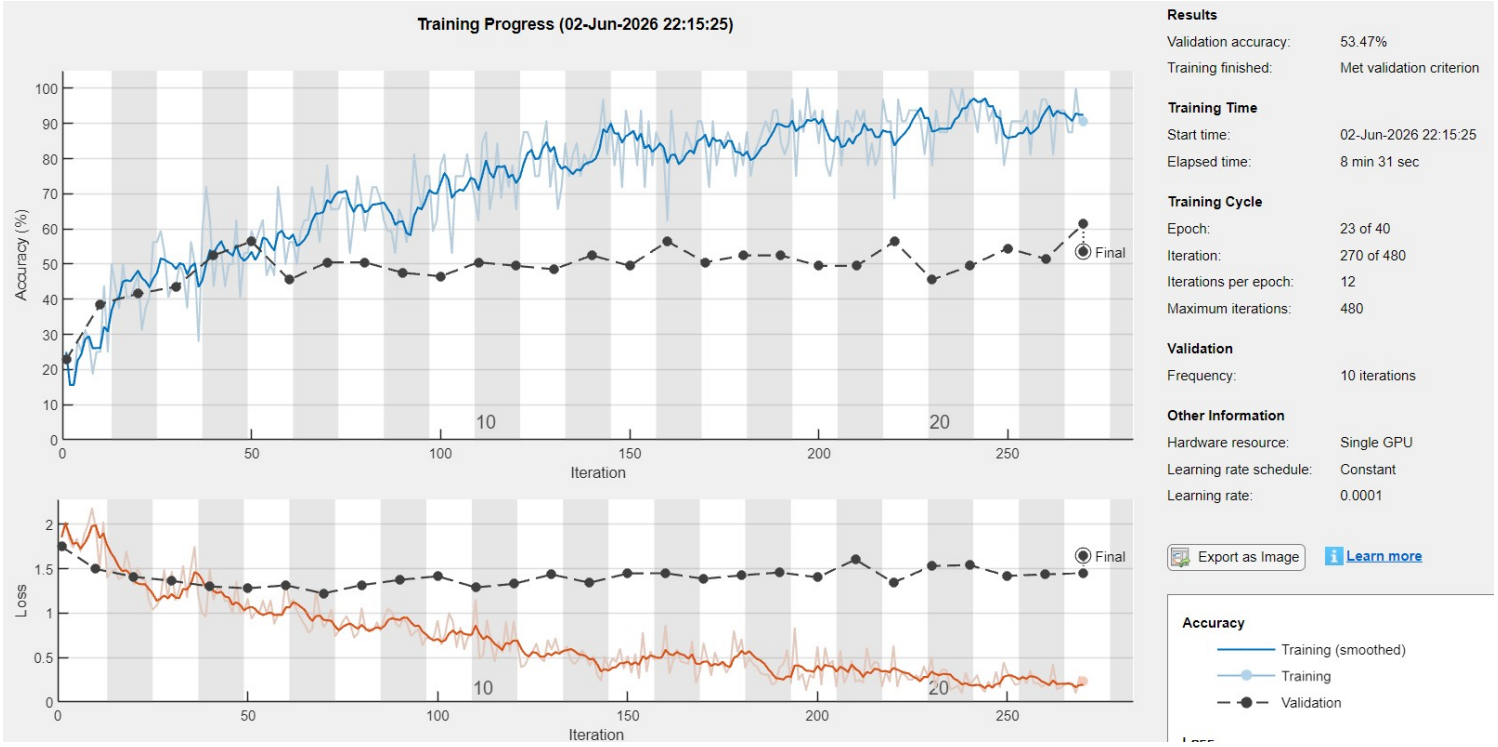


Figura: Prueba 1

Experimentos Realizados

- Segunda prueba con ResNet50

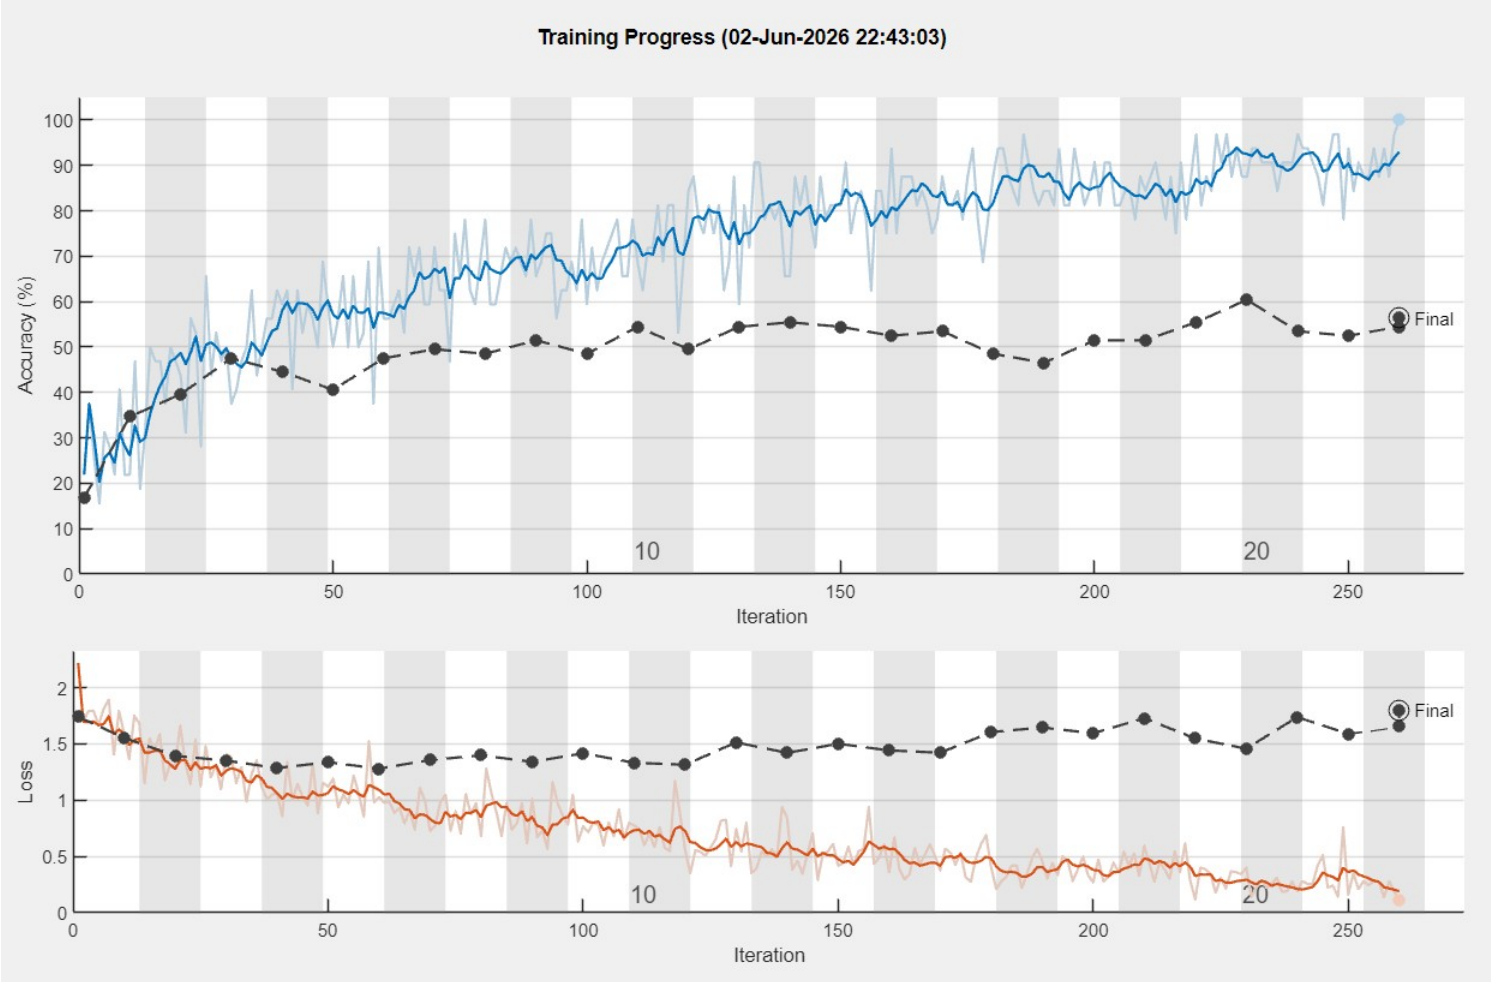


Figura: Prueba 2

Experimentos Realizados

- Primera prueba con DenseNet50

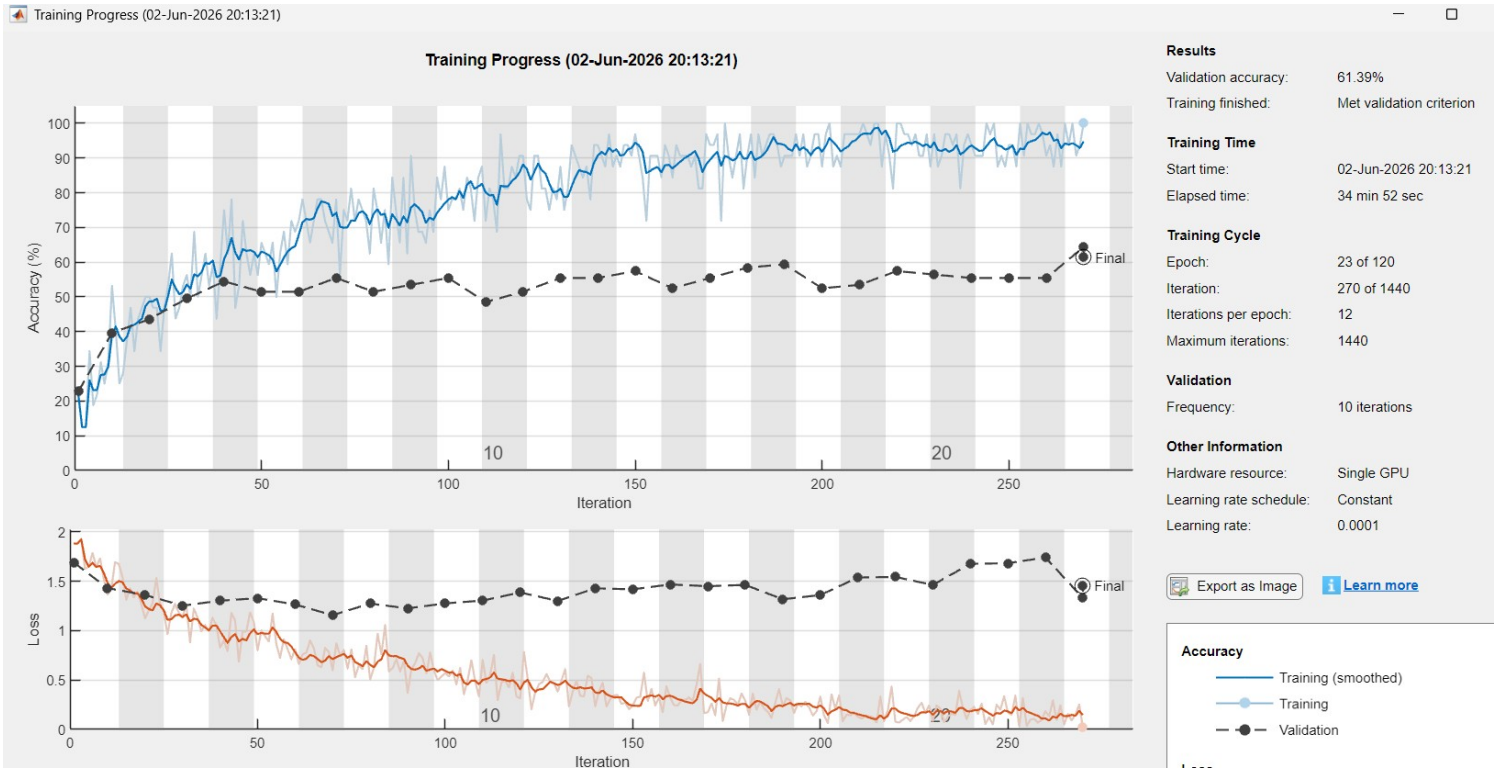


Figura: Prueba 1

Experimentos Realizados

- Segunda prueba con DenseNet50

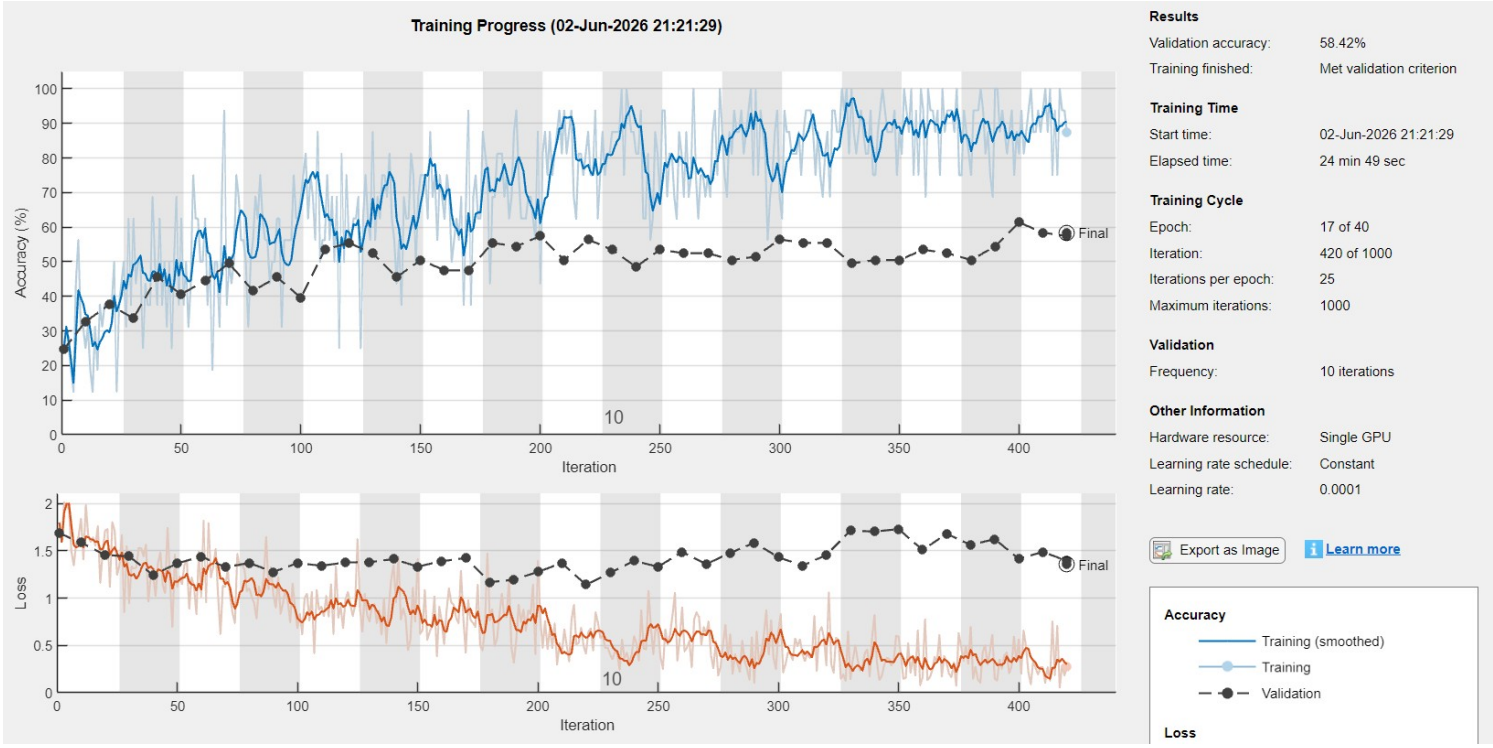


Figura: Prueba 2

Resultados Globales

Cuadro: Comparación de resultados obtenidos con las diferentes arquitecturas CNN

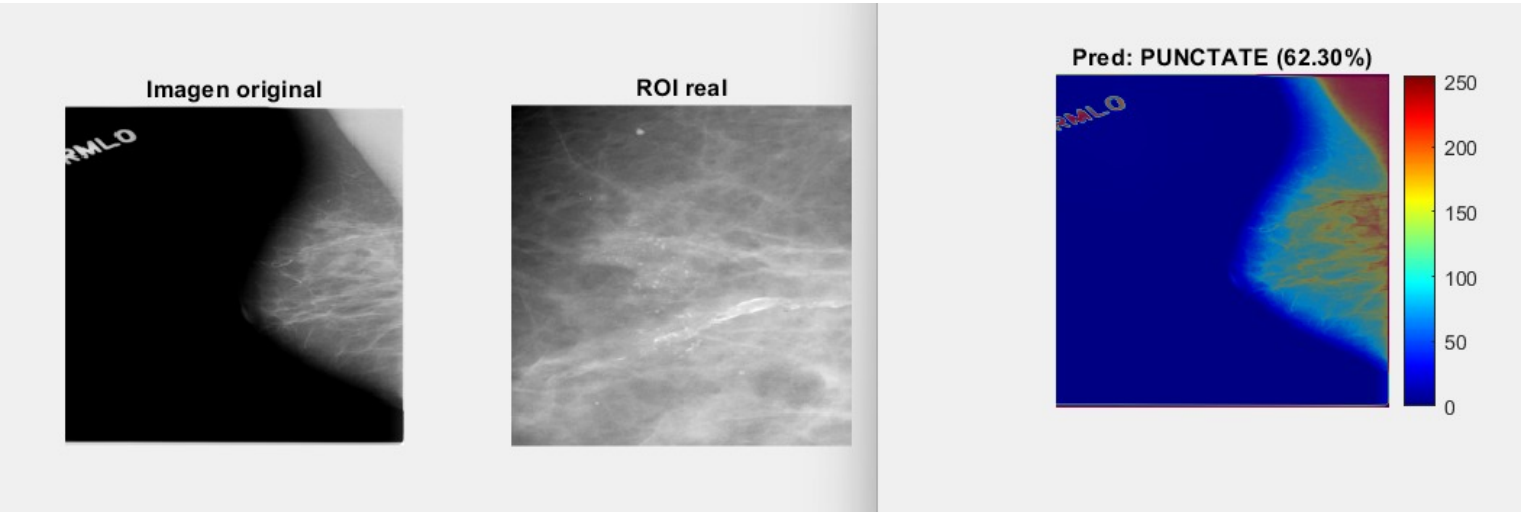
Modelo	**Accuracy**	**F1-Score**	**Recall**
ResNet18 (Prueba 1)	48.56 %	47.07 %	47.67 %
ResNet18 (Prueba 2)	52.01 %	49.54 %	49.38 %
ResNet50 (Prueba 1)	52.30 %	52.51 %	53.57 %
ResNet50 (Prueba 2)	55.33 %	55.26 %	56.76 %
DenseNet201 (Prueba 1)	60.97 %	60.29 %	61.43 %
DenseNet201 (Prueba 2)	58.32 %	58.15 %	58.52 %

Análisis de Resultados

- DenseNet201 supera a ResNet50 en promedio.
- Mayor estabilidad en métricas de validación.
- ResNet50 presenta mayor variabilidad entre pruebas.
- Evidencia de sensibilidad al entrenamiento.

Grad-CAM

- Permite visualizar regiones importantes para la decisión.
- Superposición sobre mamografía original.
- Validación de atención del modelo en zonas clínicas relevantes.



Interfaz CAD

- Desarrollo en MATLAB App Designer.
- Generación de casos clínicos aleatorios.
- Visualización de:
  - Mamografía
  - ROI
  - Grad-CAM
  - Probabilidades

Interfaz y distribucion

- Panel de control (evaluación del modelo)

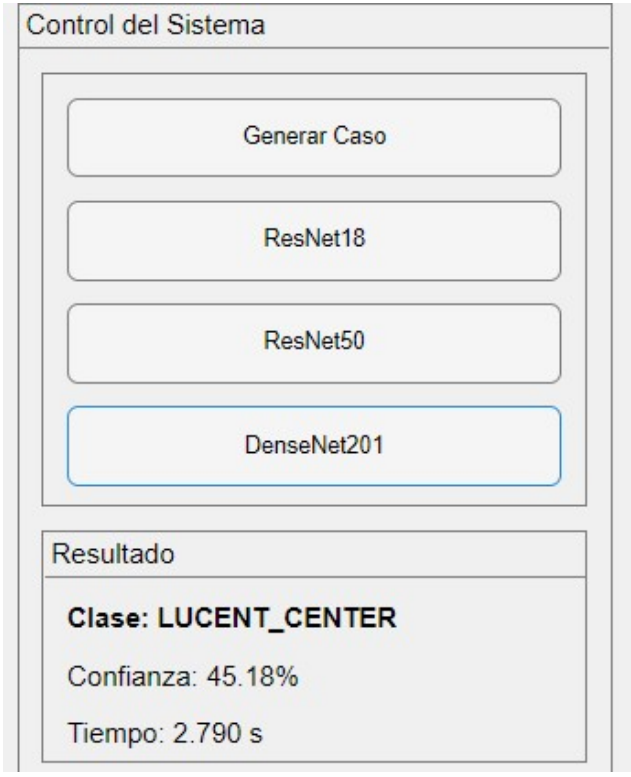


Figura: Panel de control

Interfaz y distribucion

- Panel de imagen médica

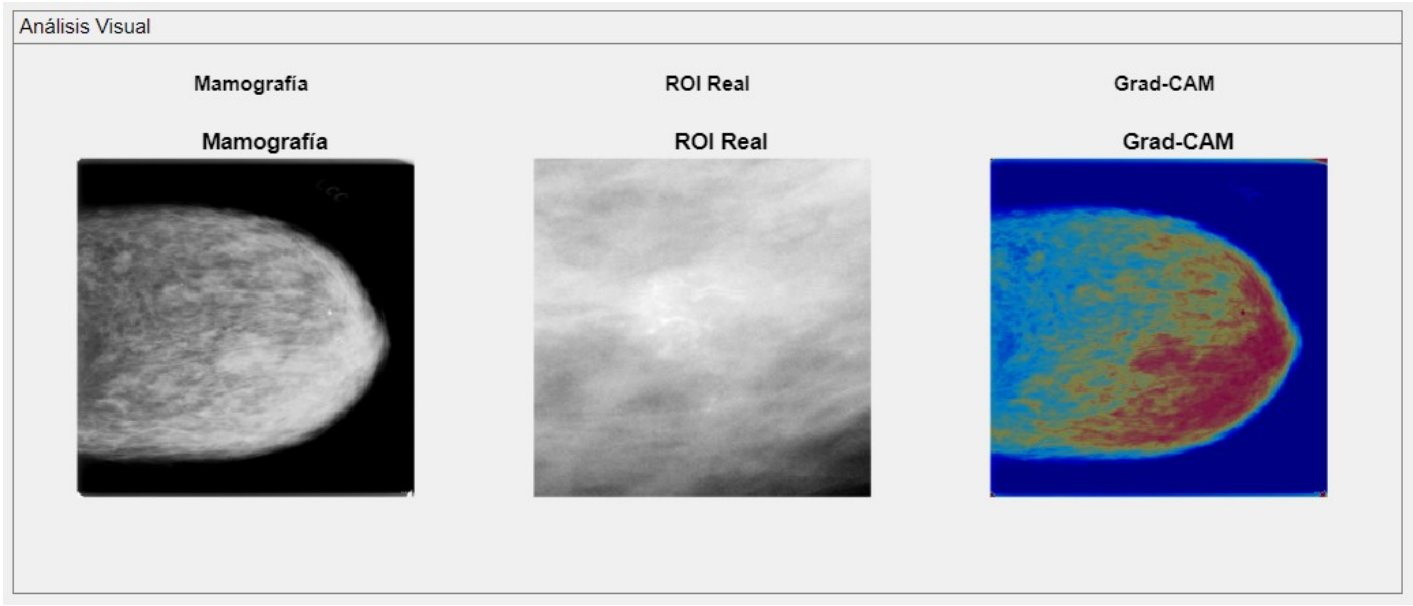


Figura: Imagenes medicas

Interfaz y distribucion

- Panel de probabilidades

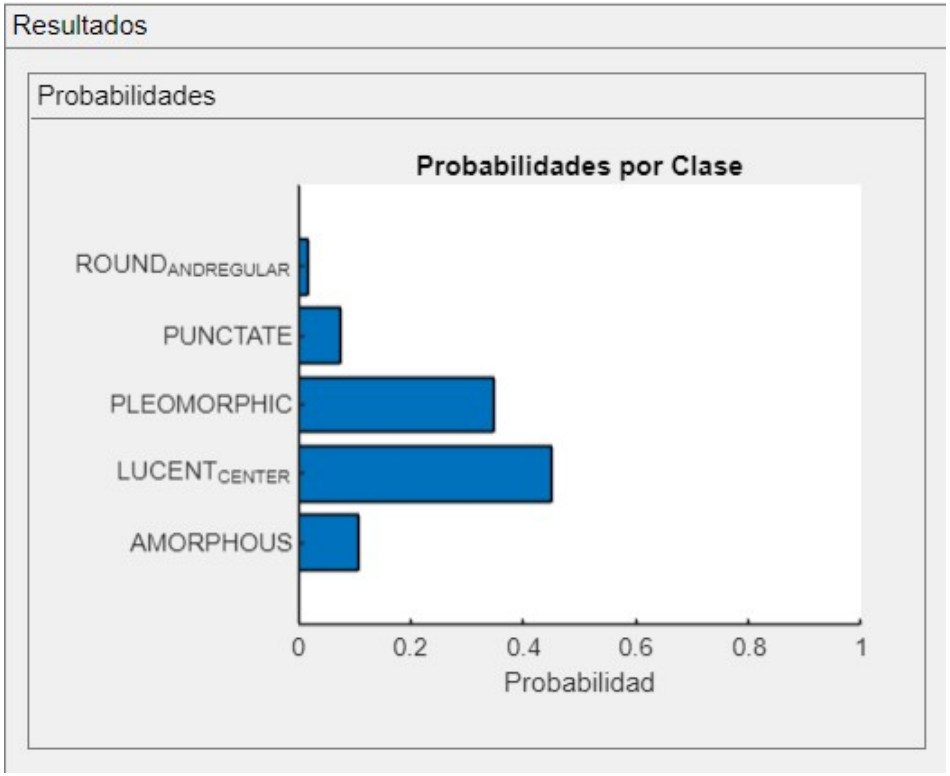


Figura: Probabilidades por clase

Interfaz y distribucion

- Panel de métricas y matriz de confusión



Figura: Matriz de confusion

Interfaz y distribucion

- Panel de historial de entrenamiento

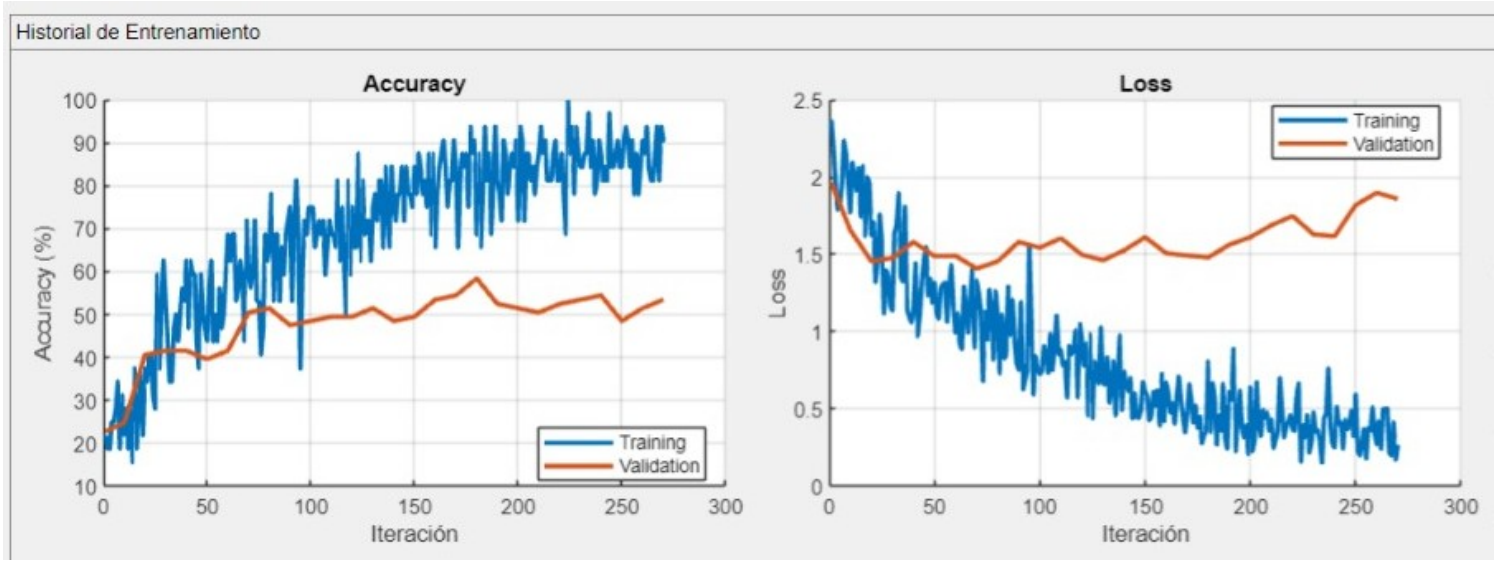


Figura: Graficas de entrenamiento

Interfaz CAD

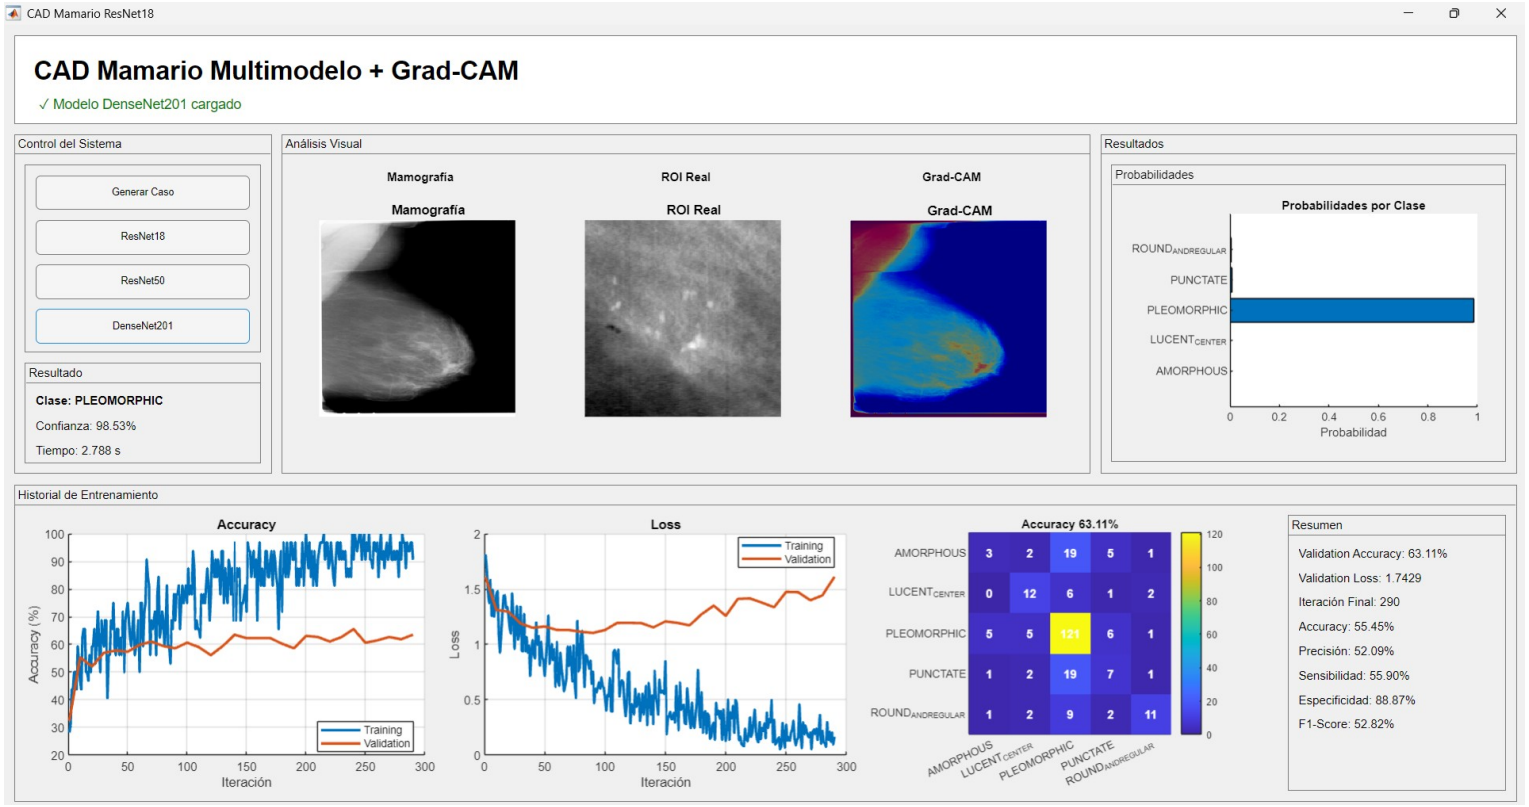


Figura: Interfaz de usuario

Conclusiones

- Se desarrolló exitosamente un sistema CAD (Computer-Aided Diagnosis) capaz de clasificar automáticamente cinco tipos morfológicos de calcificaciones mamarias utilizando técnicas de Transfer Learning sobre la base de datos CBIS-DDSM.
- DenseNet201 obtuvo el mejor desempeño global del proyecto, alcanzando una exactitud del 60.97 %, un Recall de 61.43 % y un F1-score de 60.29 %, superando a ResNet18 y ResNet50 en la mayoría de métricas evaluadas.

Conclusiones

- ResNet18 mostró una mejora significativa respecto a sus primeras pruebas, incrementando el F1-score desde 47.07 % hasta 59.54 %, evidenciando la importancia del ajuste de hiperparámetros y del procesamiento previo de las imágenes.
- La alta especificidad obtenida por ResNet18 (89.86 %) indica una baja tasa de falsos positivos, característica deseable en sistemas de apoyo al diagnóstico para evitar procedimientos clínicos innecesarios.

Conclusiones

- Los mapas Grad-CAM demostraron que las redes neuronales enfocan su atención sobre regiones compatibles con las áreas de calcificación identificadas por las máscaras ROI, aportando interpretabilidad y confianza en las predicciones generadas.
- La interfaz gráfica desarrollada en MATLAB integra clasificación, visualización de probabilidades, análisis de Grad-CAM, métricas de desempeño e historial de entrenamiento, proporcionando una herramienta completa para la evaluación de modelos de diagnóstico asistido por computador.